Global Video Game Sales & Ratings

Metodología CRISP-DM

Carlos Cao C.I. 28.655.925
César Carios C.I. 30.136.117
Miguel Ciavato C.I. 30.541.929

6213 - Minería de Datos
Facultad de ciencias
Universidad Central de Venezuela

Contenido

1. Fase 1: Comprensión del Negocio
2. Fase 2: Comprensión de los Datos
3. Fase 3: Preparación de Datos
4. Fases 4 y 5: Modelado y Evaluación
5. Fase 6: Despliegue (Deployment)

*"Sin datos, sólo eres otra persona con una opinión."**

*W. Edwards Deming

El Valor Oculto en la Industria Gaming

- **El Riesgo del Éxito:** Desarrollar un videojuego hoy en día implica ciclos masivos de inversión (dinero, tiempo, talento). Un fracaso en ventas puede quebrar un estudio.
- **Más allá del Código:** ¿Qué hace que un juego venda millones? ¿Es el género, la plataforma, o la recepción de la crítica?
- **Big Data en Acción:** Históricamente, la industria dependía de la intuición. Hoy, la *Minería de Datos* permite decodificar las preferencias del mercado a partir del legado dejado por miles de títulos.

Nuestra Misión

Transformar años de métricas y metadatos históricos en un mapa de ruta estratégico para el desarrollo interactivo.

El Valor Oculto en la Industria Gaming

- **El Riesgo del Éxito:** Desarrollar un videojuego hoy en día implica ciclos masivos de inversión (dinero, tiempo, talento). Un fracaso en ventas puede quebrar un estudio.
- **Más allá del Código:** ¿Qué hace que un juego venda millones? ¿Es el género, la plataforma, o la recepción de la crítica?
- **Big Data en Acción:** Históricamente, la industria dependía de la intuición. Hoy, la *Minería de Datos* permite decodificar las preferencias del mercado a partir del legado dejado por miles de títulos.

Nuestra Misión

Transformar años de métricas y metadatos históricos en un mapa de ruta estratégico para el desarrollo interactivo.

El Valor Oculto en la Industria Gaming

- **El Riesgo del Éxito:** Desarrollar un videojuego hoy en día implica ciclos masivos de inversión (dinero, tiempo, talento). Un fracaso en ventas puede quebrar un estudio.
- **Más allá del Código:** ¿Qué hace que un juego venda millones? ¿Es el género, la plataforma, o la recepción de la crítica?
- **Big Data en Acción:** Históricamente, la industria dependía de la intuición. Hoy, la *Minería de Datos* permite decodificar las preferencias del mercado a partir del legado dejado por miles de títulos.

Nuestra Misión

Transformar años de métricas y metadatos históricos en un mapa de ruta estratégico para el desarrollo interactivo.

El Valor Oculto en la Industria Gaming

- **El Riesgo del Éxito:** Desarrollar un videojuego hoy en día implica ciclos masivos de inversión (dinero, tiempo, talento). Un fracaso en ventas puede quebrar un estudio.
- **Más allá del Código:** ¿Qué hace que un juego venda millones? ¿Es el género, la plataforma, o la recepción de la crítica?
- **Big Data en Acción:** Históricamente, la industria dependía de la intuición. Hoy, la *Minería de Datos* permite decodificar las preferencias del mercado a partir del legado dejado por miles de títulos.

Nuestra Misión

Transformar años de métricas y metadatos históricos en un mapa de ruta estratégico para el desarrollo interactivo.

El Valor Oculto en la Industria Gaming

- **El Riesgo del Éxito:** Desarrollar un videojuego hoy en día implica ciclos masivos de inversión (dinero, tiempo, talento). Un fracaso en ventas puede quebrar un estudio.
- **Más allá del Código:** ¿Qué hace que un juego venda millones? ¿Es el género, la plataforma, o la recepción de la crítica?
- **Big Data en Acción:** Históricamente, la industria dependía de la intuición. Hoy, la *Minería de Datos* permite decodificar las preferencias del mercado a partir del legado dejado por miles de títulos.

Nuestra Misión

Transformar años de métricas y metadatos históricos en un mapa de ruta estratégico para el desarrollo interactivo.

Planteamiento y Viabilidad del Proyecto

- **El Núcleo del Problema:** Existen múltiples factores interconectados (notas de usuarios, scores de críticos, géneros, publicadores) que afectan el desempeño comercial de un título, pero su peso e impacto son inciertos.
- **Objetivo Analítico:** Aspiramos a construir un modelo capaz de anticipar el alcance comercial global (`Global_Sales`) de un producto interactivo basándonos exclusivamente en sus especificaciones y recepción pública.
- **La Incógnita a Resolver:** *¿Existen verdaderamente patrones matemáticos predictibles que garanticen, o al menos perfilen, el triunfo de un videojuego antes o durante su ciclo de vida en el mercado?*

Planteamiento y Viabilidad del Proyecto

- **El Núcleo del Problema:** Existen múltiples factores interconectados (notas de usuarios, scores de críticos, géneros, publicadores) que afectan el desempeño comercial de un título, pero su peso e impacto son inciertos.
- **Objetivo Analítico:** Aspiramos a construir un modelo capaz de anticipar el alcance comercial global (`Global_Sales`) de un producto interactivo basándonos exclusivamente en sus especificaciones y recepción pública.
- **La Incógnita a Resolver:** *¿Existen verdaderamente patrones matemáticos predictibles que garanticen, o al menos perfilen, el triunfo de un videojuego antes o durante su ciclo de vida en el mercado?*

Planteamiento y Viabilidad del Proyecto

- **El Núcleo del Problema:** Existen múltiples factores interconectados (notas de usuarios, scores de críticos, géneros, publicadores) que afectan el desempeño comercial de un título, pero su peso e impacto son inciertos.
- **Objetivo Analítico:** Aspiramos a construir un modelo capaz de anticipar el alcance comercial global (`Global_Sales`) de un producto interactivo basándonos exclusivamente en sus especificaciones y recepción pública.
- **La Incógnita a Resolver:** *¿Existen verdaderamente patrones matemáticos predictibles que garanticen, o al menos perfilen, el triunfo de un videojuego antes o durante su ciclo de vida en el mercado?*

Inventario de Datos

Origen: Kaggle - Global Video Game Sales & Ratings ($\approx 6,800$ juegos)

Name	Platform	Genre	Global_Sales	Critic_Score	Rating	Story Focus	Series
.hack//Infection Part 1	PS2	Role-Playing	1.27	75.0	T	x	x
[Prototype]	X360	Action	1.31	78.0	M	NaN	x
100 Classic Books	DS	Misc	0.66	70.0	N/A	NaN	NaN
...	...	...	...	...	...	...	...

Tabla: Muestra del dataset proveniente de Tagged-Data-Final.csv

- **Numéricas:** `Ventas`, `Critic_Score`, `User_Score`.
- **Categóricas:** `Genre`, `Publisher`, `Developer`, `Rating`.
- **Lógicas/Binarias:** `Story Focus`, `Gameplay Focus`, `Series` $\leftarrow$ (Ruido alto).
- **Variable Objetivo:** Predecir Ventas Globales (`Global_Sales`).

Inventario de Datos

Origen: Kaggle - Global Video Game Sales & Ratings ($\approx 6,800$ juegos)

Name	Platform	Genre	Global_Sales	Critic_Score	Rating	Story Focus	Series
.hack//Infection Part 1	PS2	Role-Playing	1.27	75.0	T	x	x
[Prototype]	X360	Action	1.31	78.0	M	NaN	x
100 Classic Books	DS	Misc	0.66	70.0	N/A	NaN	NaN
...	...	...	...	...	...	...	...

Tabla: Muestra del dataset proveniente de Tagged-Data-Final.csv

- **Numéricas:** `Ventas`, `Critic_Score`, `User_Score`.
- **Categóricas:** `Genre`, `Publisher`, `Developer`, `Rating`.
- **Lógicas/Binarias:** `Story Focus`, `Gameplay Focus`, `Series` $\leftarrow$ (Ruido alto).
- **Variable Objetivo:** Predecir Ventas Globales (`Global_Sales`).

Inventario de Datos

Origen: Kaggle - Global Video Game Sales & Ratings ($\approx 6,800$ juegos)

Name	Platform	Genre	Global_Sales	Critic_Score	Rating	Story Focus	Series
.hack//Infection Part 1	PS2	Role-Playing	1.27	75.0	T	x	x
[Prototype]	X360	Action	1.31	78.0	M	NaN	x
100 Classic Books	DS	Misc	0.66	70.0	N/A	NaN	NaN
...	...	...	...	...	...	...	...

Tabla: Muestra del dataset proveniente de Tagged-Data-Final.csv

- **Numéricas:** `Ventas`, `Critic_Score`, `User_Score`.
- **Categóricas:** `Genre`, `Publisher`, `Developer`, `Rating`.
- **Lógicas/Binarias:** `Story Focus`, `Gameplay Focus`, `Series` $\leftarrow$ (Ruido alto).
- **Variable Objetivo:** Predecir Ventas Globales (`Global_Sales`).

Inventario de Datos

Origen: Kaggle - Global Video Game Sales & Ratings ($\approx 6,800$ juegos)

Name	Platform	Genre	Global_Sales	Critic_Score	Rating	Story Focus	Series
.hack//Infection Part 1	PS2	Role-Playing	1.27	75.0	T	x	x
[Prototype]	X360	Action	1.31	78.0	M	NaN	x
100 Classic Books	DS	Misc	0.66	70.0	N/A	NaN	NaN
...	...	...	...	...	...	...	...

Tabla: Muestra del dataset proveniente de Tagged-Data-Final.csv

- **Numéricas:** `Ventas`, `Critic_Score`, `User_Score`.
- **Categóricas:** `Genre`, `Publisher`, `Developer`, `Rating`.
- **Lógicas/Binarias:** `Story Focus`, `Gameplay Focus`, `Series` $\leftarrow$ (Ruido alto).
- **Variable Objetivo:** Predecir Ventas Globales (`Global_Sales`).

Análisis Exploratorio: El Fenómeno Long-Tail

- **Asimetría Positiva Extrema:** La distribución de ventas no sigue una distribución normal perfecta, tiene una larga cola hacia la derecha (Right-Skewed).
- **Realidad Económica:** La inmensa mayoría de juegos fracasa o vende menos de la media histórica (0.77M). Una ínfima minoría logra viralidad y ventas masivas.
- **Reto Matemático:** Predecir estos megaéxitos (valores atípicos) será el mayor desafío para el algoritmo.

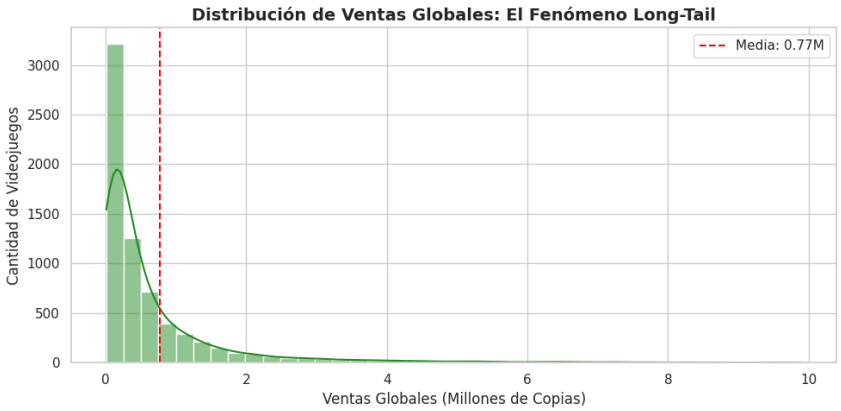

Análisis Exploratorio: El Fenómeno Long-Tail

- **Asimetría Positiva Extrema:** La distribución de ventas no sigue una distribución normal perfecta, tiene una larga cola hacia la derecha (Right-Skewed).
- **Realidad Económica:** La inmensa mayoría de juegos fracasa o vende menos de la media histórica (0.77M). Una ínfima minoría logra viralidad y ventas masivas.
- **Reto Matemático:** Predecir estos megaéxitos (valores atípicos) será el mayor desafío para el algoritmo.

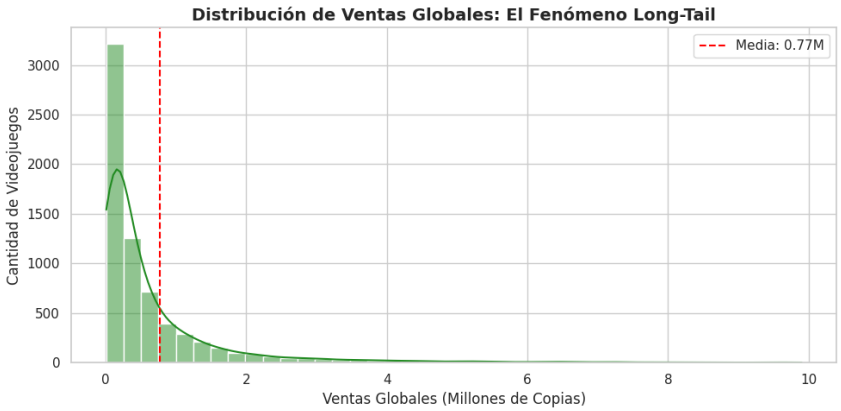

Análisis Exploratorio: El Fenómeno Long-Tail

- **Asimetría Positiva Extrema:** La distribución de ventas no sigue una distribución normal perfecta, tiene una larga cola hacia la derecha (Right-Skewed).
- **Realidad Económica:** La inmensa mayoría de juegos fracasa o vende menos de la media histórica (0.77M). Una ínfima minoría logra viralidad y ventas masivas.
- **Reto Matemático:** Predecir estos megaéxitos (valores atípicos) será el mayor desafío para el algoritmo.

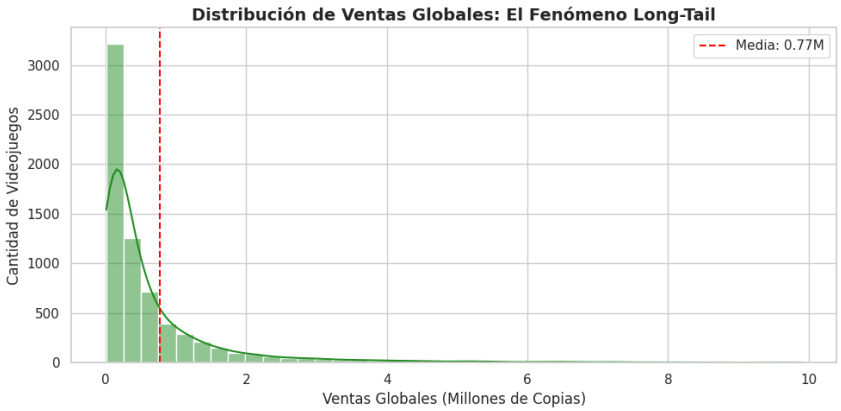

Análisis Exploratorio: El Fenómeno Long-Tail

- **Asimetría Positiva Extrema:** La distribución de ventas no sigue una distribución normal perfecta, tiene una larga cola hacia la derecha (Right-Skewed).
- **Realidad Económica:** La inmensa mayoría de juegos fracasa o vende menos de la media histórica (0.77M). Una ínfima minoría logra viralidad y ventas masivas.
- **Reto Matemático:** Predecir estos megaéxitos (valores atípicos) será el mayor desafío para el algoritmo.

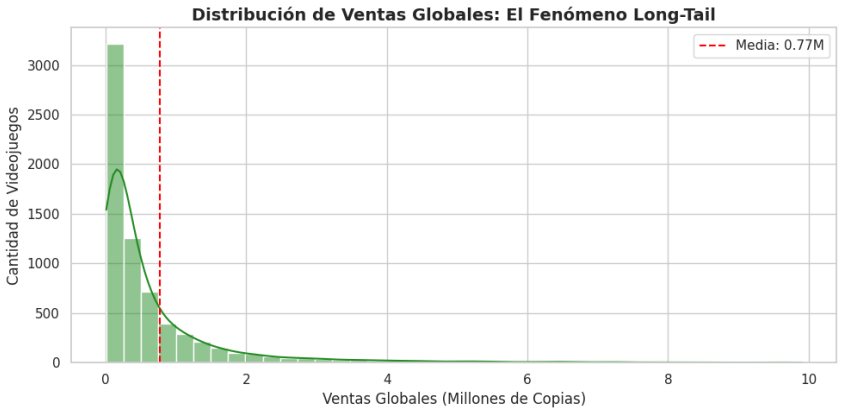

Análisis Exploratorio: El Fenómeno Long-Tail

- **Asimetría Positiva Extrema:** La distribución de ventas no sigue una distribución normal perfecta, tiene una larga cola hacia la derecha (Right-Skewed).
- **Realidad Económica:** La inmensa mayoría de juegos fracasa o vende menos de la media histórica (0.77M). Una ínfima minoría logra viralidad y ventas masivas.
- **Reto Matemático:** Predecir estos megaéxitos (valores atípicos) será el mayor desafío para el algoritmo.

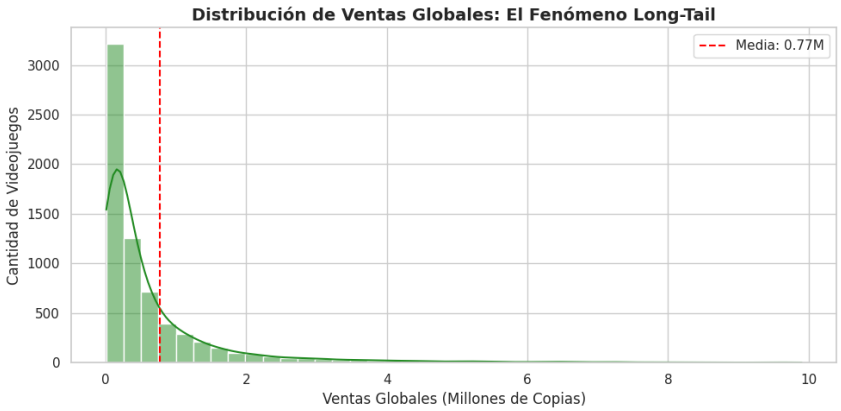

Matriz de Correlación

- **Relaciones Lineales:** Detección de una altísima correlación (≈ 0.90) entre las ventas de Norteamérica (NA_Sales) y Europa (EU_Sales).
- **Decisión Técnica:** Se confirma matemáticamente la alta redundancia de la información que aportan.

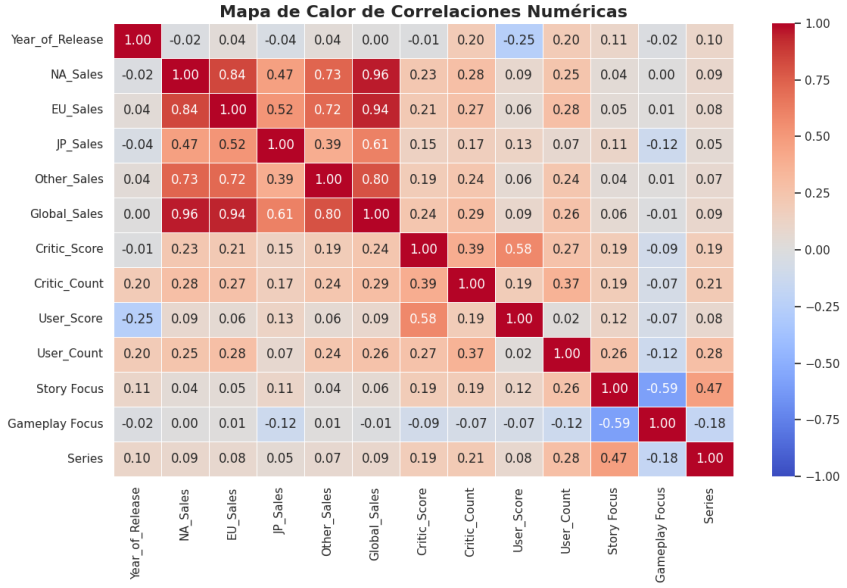

Matriz de Correlación

- **Relaciones Lineales:** Detección de una altísima correlación (≈ 0.90) entre las ventas de Norteamérica (NA_Sales) y Europa (EU_Sales).
- **Decisión Técnica:** Se confirma matemáticamente la alta redundancia de la información que aportan.

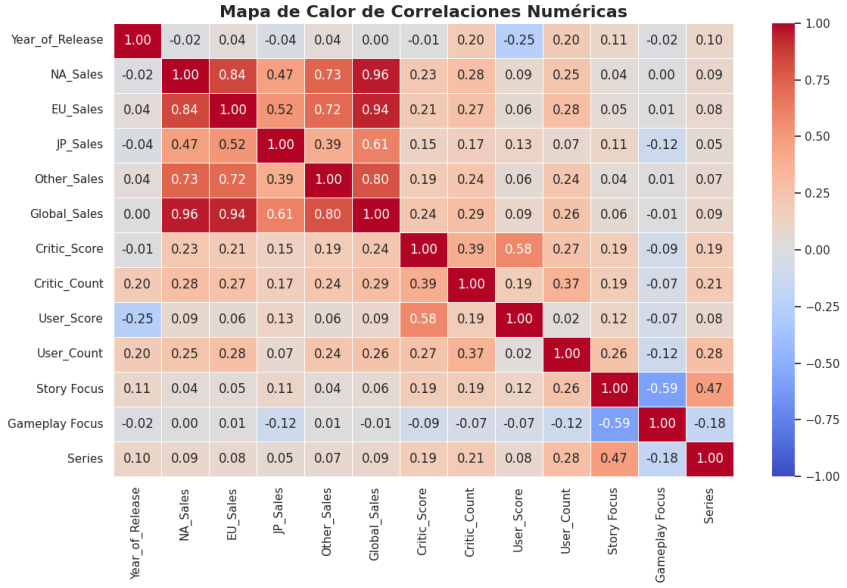

Matriz de Correlación

- **Relaciones Lineales:** Detección de una altísima correlación (≈ 0.90) entre las ventas de Norteamérica (NA_Sales) y Europa (EU_Sales).
- **Decisión Técnica:** Se confirma matemáticamente la alta redundancia de la información que aportan.

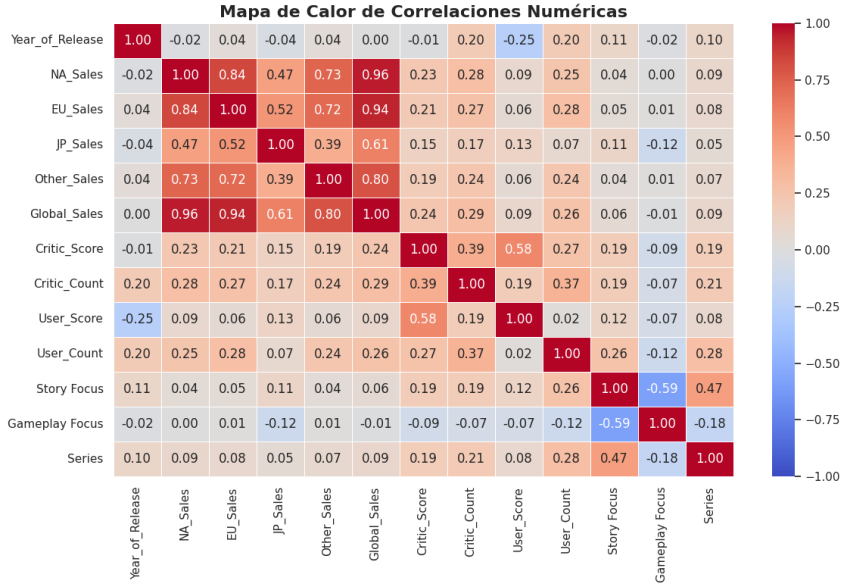

Matriz de Correlación

- **Relaciones Lineales:** Detección de una altísima correlación (≈ 0.90) entre las ventas de Norteamérica (NA_Sales) y Europa (EU_Sales).
- **Decisión Técnica:** Se confirma matemáticamente la alta redundancia de la información que aportan.

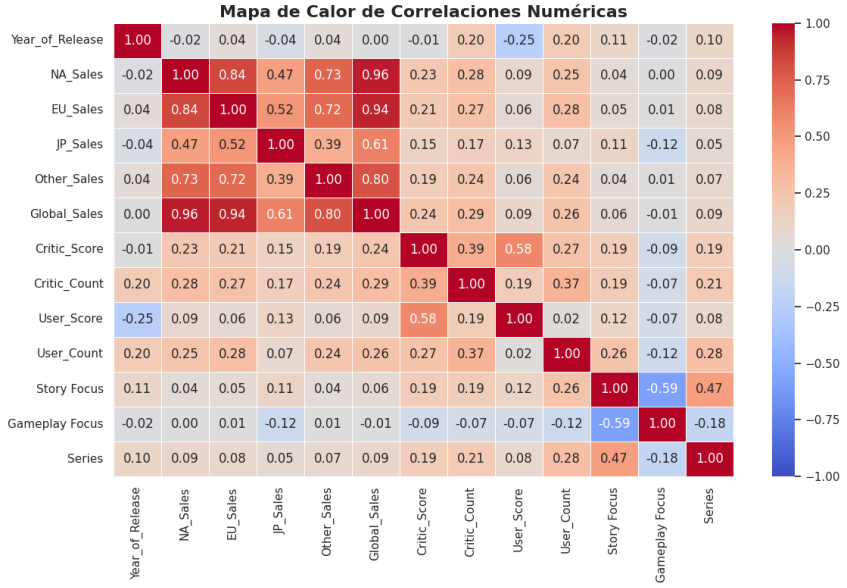

Multicolinealidad y Target Leakage

- **Fobia a la Fuga de Información (Target Leakage):** Si incluyéramos cualquier venta regional (`NA_Sales`, `EU_Sales`) para predecir las ventas globales (`Global_Sales`), cometeríamos una trampa algorítmica.
- **Decisión:** Se excluyen rigurosamente todas las variables de ventas regionales de la fase predictiva.

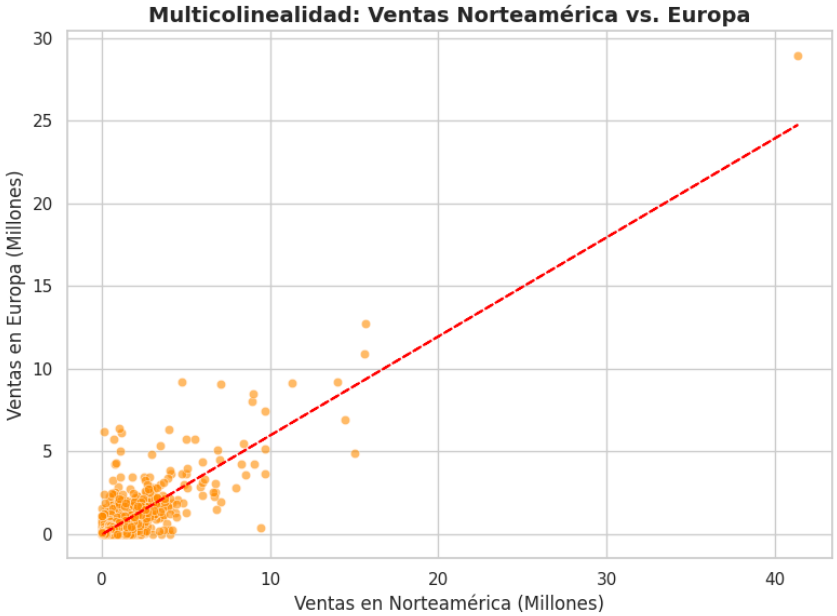

Multicolinealidad y Target Leakage

- **Fobia a la Fuga de Información (Target Leakage):** Si incluyéramos cualquier venta regional (`NA_Sales`, `EU_Sales`) para predecir las ventas globales (`Global_Sales`), cometeríamos una trampa algorítmica.
- **Decisión:** Se excluyen rigurosamente todas las variables de ventas regionales de la fase predictiva.

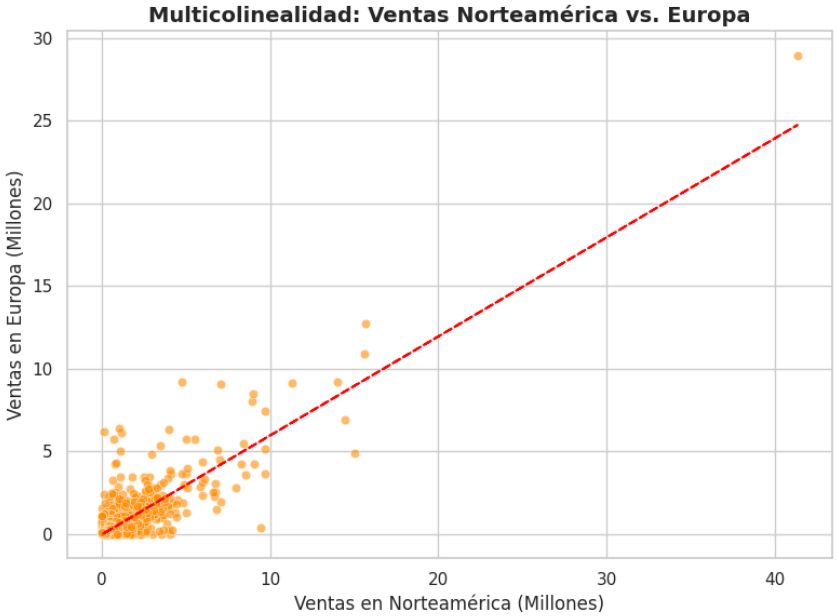

Multicolinealidad y Target Leakage

- **Fobia a la Fuga de Información (Target Leakage):** Si incluyéramos cualquier venta regional (`NA_Sales`, `EU_Sales`) para predecir las ventas globales (`Global_Sales`), cometeríamos una trampa algorítmica.
- **Decisión:** Se excluyen rigurosamente todas las variables de ventas regionales de la fase predictiva.

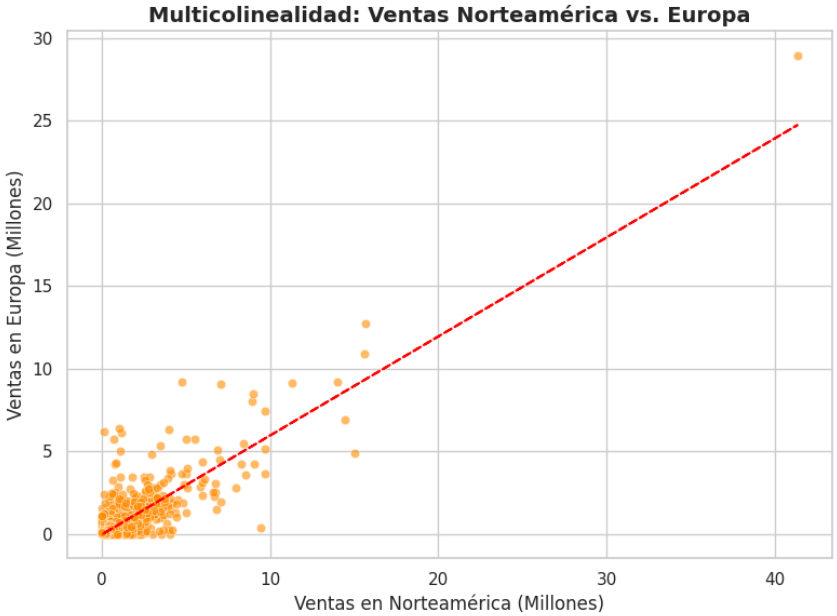

Multicolinealidad y Target Leakage

- **Fobia a la Fuga de Información (Target Leakage):** Si incluyéramos cualquier venta regional (`NA_Sales`, `EU_Sales`) para predecir las ventas globales (`Global_Sales`), cometeríamos una trampa algorítmica.
- **Decisión:** Se excluyen rigurosamente todas las variables de ventas regionales de la fase predictiva.

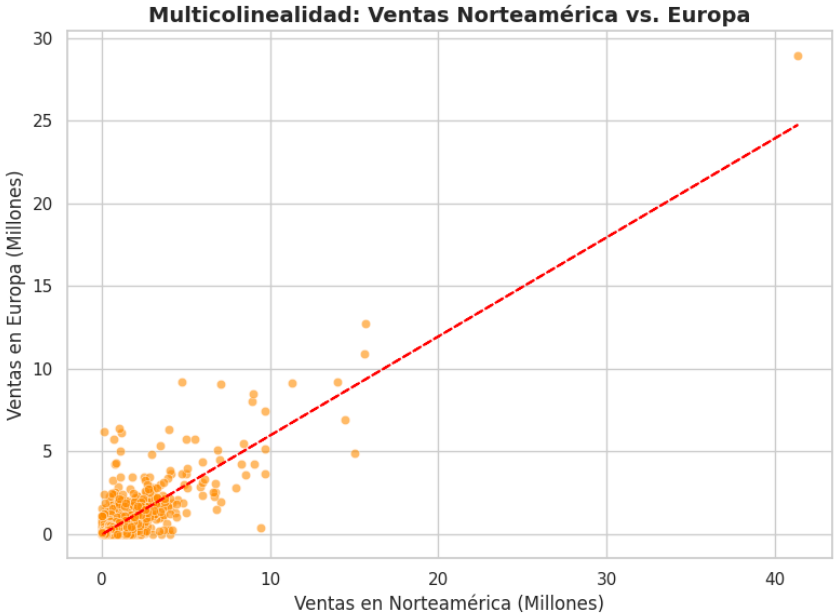

El Problema del Ruido

Datos Inconsistentes

Las variables cualitativas sobre el enfoque del juego (`Story Focus`, `Series`) superaban el 80 % de valores nulos y utilizaban el carácter 'x' para marcar presencias. Introducir esto en un algoritmo generaría un error de compilación.

- Imputar con métodos tradicionales destruiría la señal.
- Eliminar las filas con nulos significaría perder el 90 % de los videojuegos del estudio.

El Problema del Ruido

Datos Inconsistentes

Las variables cualitativas sobre el enfoque del juego (`Story Focus`, `Series`) superaban el 80 % de valores nulos y utilizaban el carácter 'x' para marcar presencias. Introducir esto en un algoritmo generaría un error de compilación.

- Imputar con métodos tradicionales destruiría la señal.
- Eliminar las filas con nulos significaría perder el 90 % de los videojuegos del estudio.

Limpieza e Imputación Binaria

Optamos por una solución elegante para rescatar la integridad de los datos sin perder información del negocio:

Transformación Lógica

- `NaN` $\rightarrow$ **0** (Asumimos ausencia de la característica).
- `'x'` $\rightarrow$ **1** (Marcador de presencia confirmada).

Adicionalmente para `Rating` (68 nulos) y `Developer` (4 nulos) se imputó la moda o se limipiaron dichas filas sin impacto crítico.

Limpieza e Imputación Binaria

Optamos por una solución elegante para rescatar la integridad de los datos sin perder información del negocio:

Transformación Lógica

- `NaN` $\rightarrow$ **0** (Asumimos ausencia de la característica).
- `'x'` $\rightarrow$ **1** (Marcador de presencia confirmada).

Adicionalmente para `Rating` (68 nulos) y `Developer` (4 nulos) se imputó la moda o se limipiaron dichas filas sin impacto crítico.

Limpieza e Imputación Binaria

Optamos por una solución elegante para rescatar la integridad de los datos sin perder información del negocio:

Transformación Lógica

- `NaN` $\rightarrow$ **0** (Asumimos ausencia de la característica).
- `'x'` $\rightarrow$ **1** (Marcador de presencia confirmada).

Adicionalmente para `Rating` (68 nulos) y `Developer` (4 nulos) se imputó la moda o se limipiaron dichas filas sin impacto crítico.

Limpieza e Imputación Binaria

Optamos por una solución elegante para rescatar la integridad de los datos sin perder información del negocio:

Transformación Lógica

- `NaN` $\rightarrow$ **0** (Asumimos ausencia de la característica).
- `'x'` $\rightarrow$ **1** (Marcador de presencia confirmada).

Adicionalmente para `Rating` (68 nulos) y `Developer` (4 nulos) se imputó la moda o se limipiaron dichas filas sin impacto crítico.

Limpieza e Imputación Binaria

Optamos por una solución elegante para rescatar la integridad de los datos sin perder información del negocio:

Transformación Lógica

- `NaN` $\rightarrow$ **0** (Asumimos ausencia de la característica).
- `'x'` $\rightarrow$ **1** (Marcador de presencia confirmada).

Adicionalmente para `Rating` (68 nulos) y `Developer` (4 nulos) se imputó la moda o se limipiaron dichas filas sin impacto crítico.

Selección de Características y Codificación

- **Maldición de la dimensionalidad:** Eliminamos columnas de texto libre (como `Name`).
- **One-Hot Encoding:** Aplicamos codificación matricial a variables categóricas como el `Genre` y el `Rating`.
- **Práctica Estadística:** Usamos `drop_first=True` en la codificación para esquivar la **multicolinealidad perfecta** (o trampa de variables ficticias).

Entregable a ML: Una matriz de datos completamente limpia, numérica y estandarizada.

Selección de Características y Codificación

- **Maldición de la dimensionalidad:** Eliminamos columnas de texto libre (como `Name`).
- **One-Hot Encoding:** Aplicamos codificación matricial a variables categóricas como el `Genre` y el `Rating`.
- **Práctica Estadística:** Usamos `drop_first=True` en la codificación para esquivar la **multicolinealidad perfecta** (o trampa de variables ficticias).

Entregable a ML: Una matriz de datos completamente limpia, numérica y estandarizada.

Selección de Características y Codificación

- **Maldición de la dimensionalidad:** Eliminamos columnas de texto libre (como `Name`).
- **One-Hot Encoding:** Aplicamos codificación matricial a variables categóricas como el `Genre` y el `Rating`.
- **Práctica Estadística:** Usamos `drop_first=True` en la codificación para esquivar la **multicolinealidad perfecta** (o trampa de variables ficticias).

Entregable a ML: Una matriz de datos completamente limpia, numérica y estandarizada.

Selección de Características y Codificación

- **Maldición de la dimensionalidad:** Eliminamos columnas de texto libre (como `Name`).
- **One-Hot Encoding:** Aplicamos codificación matricial a variables categóricas como el `Genre` y el `Rating`.
- **Práctica Estadística:** Usamos `drop_first=True` en la codificación para esquivar la **multicolinealidad perfecta** (o trampa de variables ficticias).

Entregable a ML: Una matriz de datos completamente limpia, numérica y estandarizada.

Selección de Características y Codificación

- **Maldición de la dimensionalidad:** Eliminamos columnas de texto libre (como `Name`).
- **One-Hot Encoding:** Aplicamos codificación matricial a variables categóricas como el `Genre` y el `Rating`.
- **Práctica Estadística:** Usamos `drop_first=True` en la codificación para esquivar la **multicolinealidad perfecta** (o trampa de variables ficticias).

Entregable a ML: Una matriz de datos completamente limpia, numérica y estandarizada.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 4: Modelado y Regularización

- **Algoritmo elegido: Random Forest Regressor**.
- **Problema base:** El modelo inicial memorizó el ruido, sufriendo un grave sobreajuste (*Overfitting*).
- **Solución (Regularización):** Optimizamos hiperparámetros usando `GridSearchCV`.
  - `max_depth = 15` (Podando la profundidad).
  - `min_samples_leaf = 2`.

Esto forzó matemáticamente a los árboles a encontrar sólo patrones reales y generalizables.

Fase 5: El "Jaque Mate" Matemático

Modelos en Competencia

Entrenamos un modelo lineal base para validar nuestro nuevo enfoque.

- **Regresión Lineal (Ridge):** $R^2 = 0.20$. Destrozado por la volatilidad del mercado.
- **Random Forest Regressor:** $R^2 = 0.36$, **RMSE** $= 1.22$M.

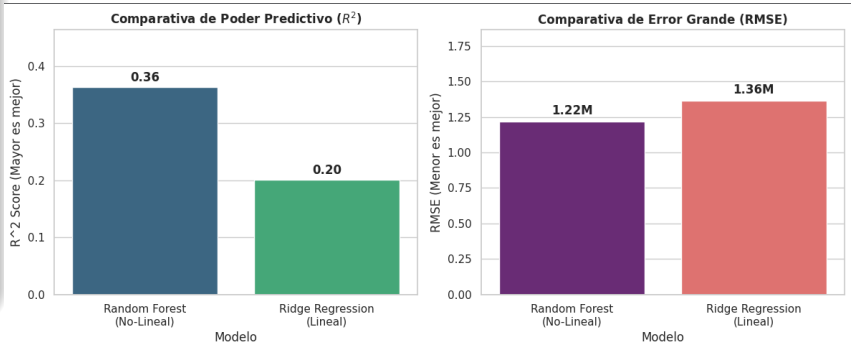

La diferencia prueba que **el éxito en los videojuegos es extremadamente complejo y no-lineal**. Nuestro modelo casi duplica la capacidad de predicción de una simple línea recta general.

Fase 5: El "Jaque Mate" Matemático

Modelos en Competencia

Entrenamos un modelo lineal base para validar nuestro nuevo enfoque.

- **Regresión Lineal (Ridge):** $R^2 = 0.20$. Destrozado por la volatilidad del mercado.
- **Random Forest Regressor:** $R^2 = 0.36$, **RMSE** $= 1.22$M.

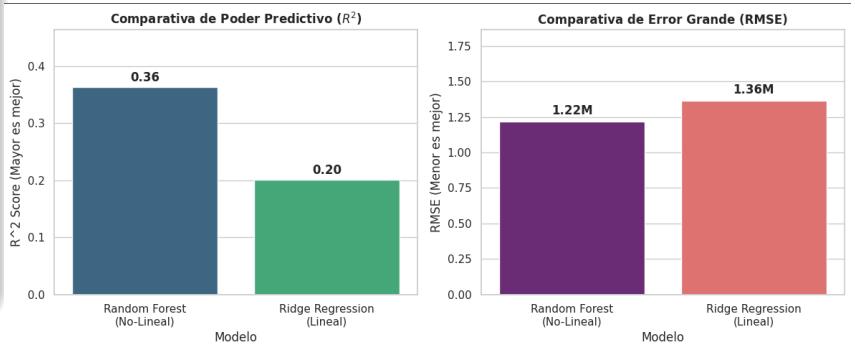

La diferencia prueba que **el éxito en los videojuegos es extremadamente complejo y no-lineal**. Nuestro modelo casi duplica la capacidad de predicción de una simple línea recta general.

Fase 5: El "Jaque Mate" Matemático

Modelos en Competencia

Entrenamos un modelo lineal base para validar nuestro nuevo enfoque.

- **Regresión Lineal (Ridge):** $R^2 = 0.20$. Destrozado por la volatilidad del mercado.
- **Random Forest Regressor:** $R^2 = 0.36$, **RMSE** $= 1.22$M.

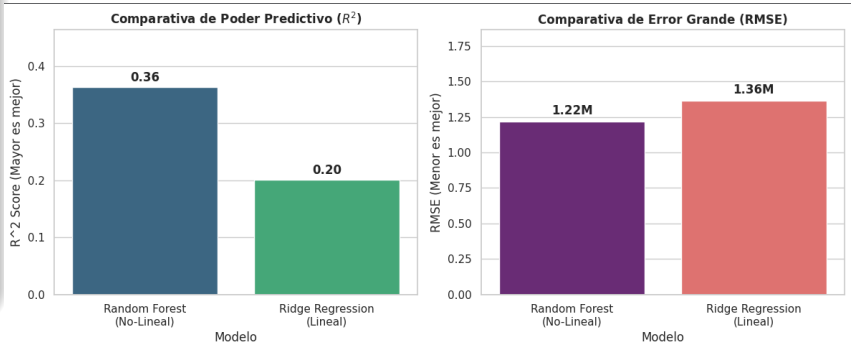

La diferencia prueba que **el éxito en los videojuegos es extremadamente complejo y no-lineal**. Nuestro modelo casi duplica la capacidad de predicción de una simple línea recta general.

Fase 5: El "Jaque Mate" Matemático

Modelos en Competencia

Entrenamos un modelo lineal base para validar nuestro nuevo enfoque.

- **Regresión Lineal (Ridge):** $R^2 = 0.20$. Destrozado por la volatilidad del mercado.
- **Random Forest Regressor:** $R^2 = 0.36$, **RMSE** $= 1.22$M.

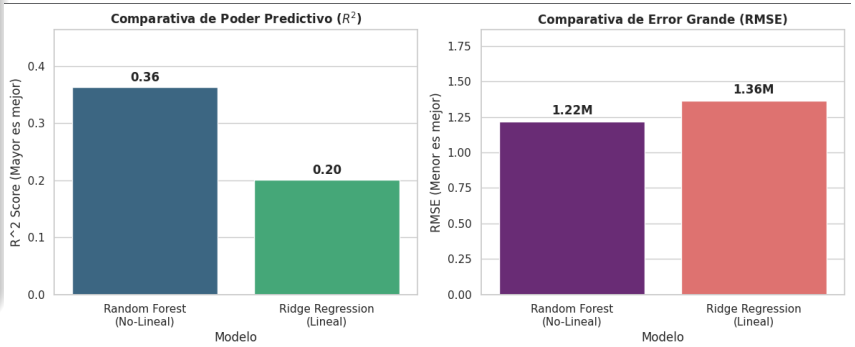

La diferencia prueba que **el éxito en los videojuegos es extremadamente complejo y no-lineal**. Nuestro modelo casi duplica la capacidad de predicción de una simple línea recta general.

Fase 5: El "Jaque Mate" Matemático

Modelos en Competencia

Entrenamos un modelo lineal base para validar nuestro nuevo enfoque.

- **Regresión Lineal (Ridge):** $R^2 = 0.20$. Destrozado por la volatilidad del mercado.
- **Random Forest Regressor:** $R^2 = 0.36$, **RMSE** $= 1.22$M.

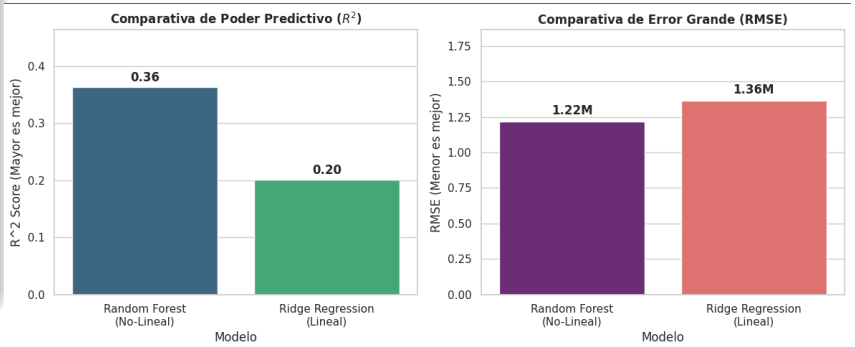

La diferencia prueba que **el éxito en los videojuegos es extremadamente complejo y no-lineal**. Nuestro modelo casi duplica la capacidad de predicción de una simple línea recta general.

Evaluación Visual: Dispersión de Predicciones

- Comparativa de las predicciones frente a los valores reales.
- El modelo regularizado reduce la dispersión extrema y se ajusta más a la línea ideal, mitigando el *Overfitting* del modelo base.

Modelo Base

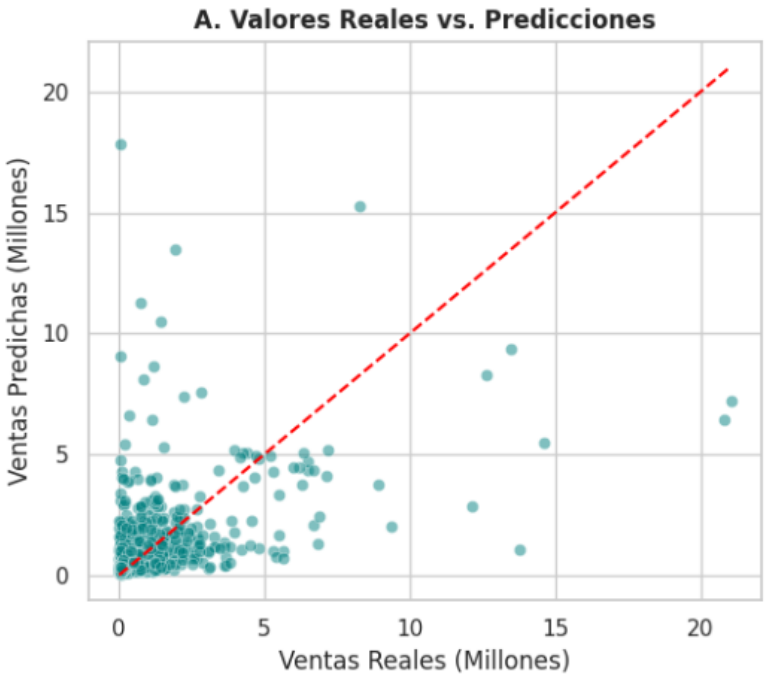

Modelo Regularizado

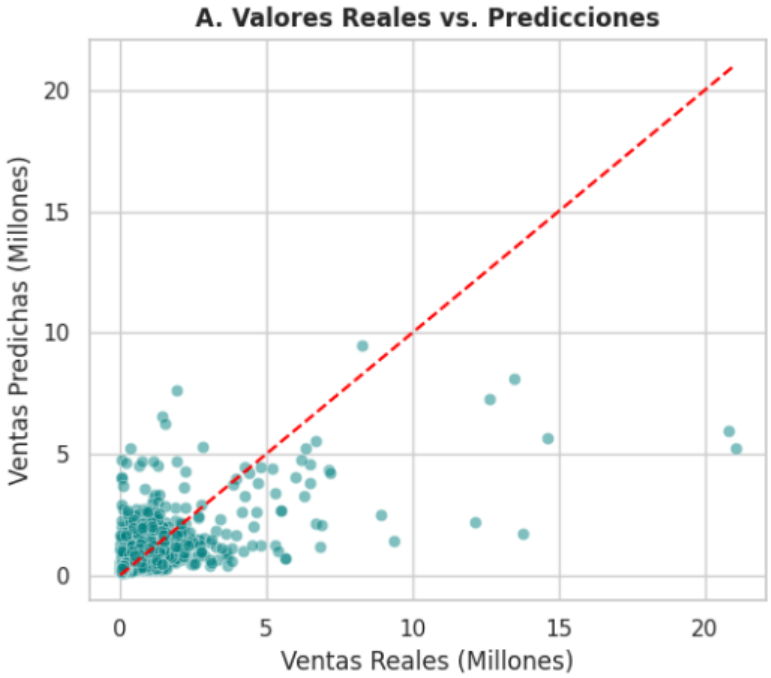

Evaluación Visual: Dispersión de Predicciones

- Comparativa de las predicciones frente a los valores reales.
- El modelo regularizado reduce la dispersión extrema y se ajusta más a la línea ideal, mitigando el *Overfitting* del modelo base.

Modelo Base

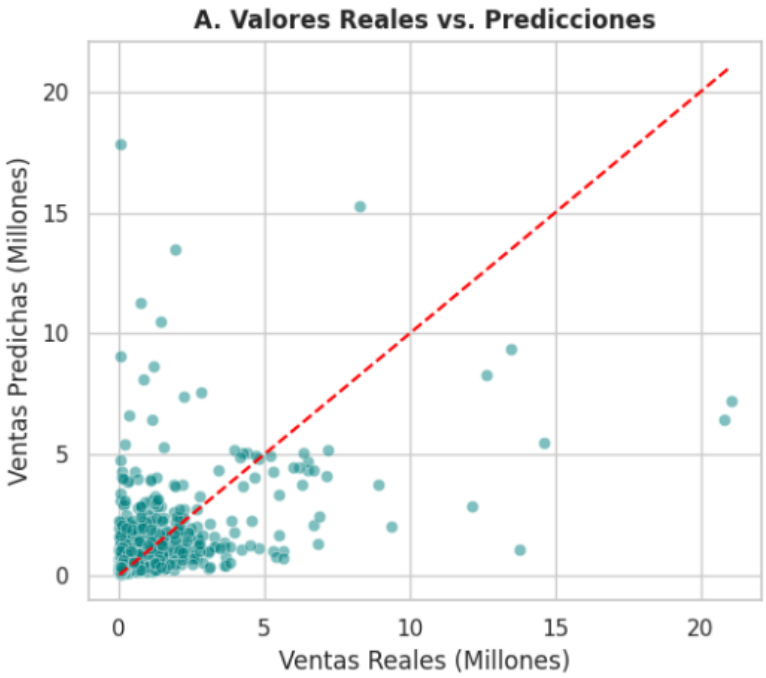

Modelo Regularizado

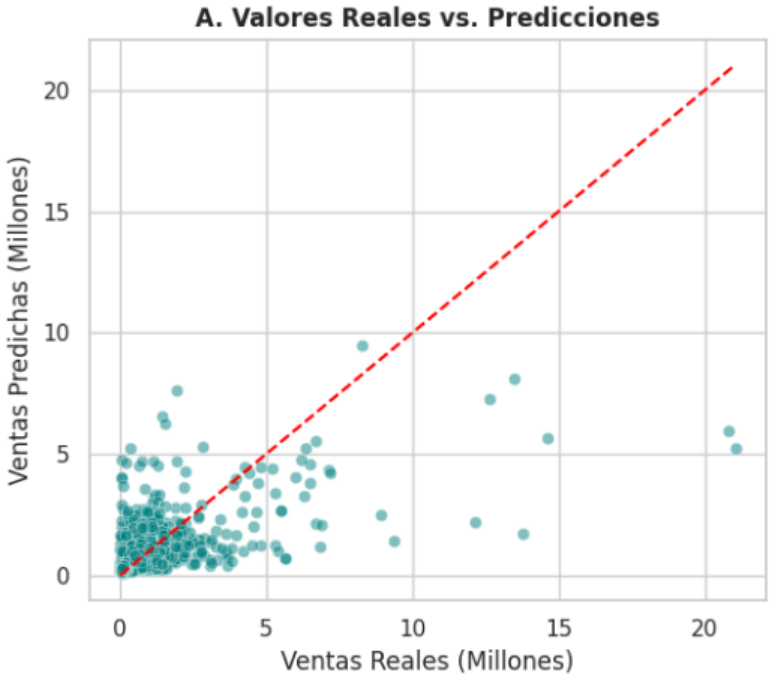

Evaluación Visual: Dispersión de Predicciones

- Comparativa de las predicciones frente a los valores reales.
- El modelo regularizado reduce la dispersión extrema y se ajusta más a la línea ideal, mitigando el *Overfitting* del modelo base.

Modelo Base

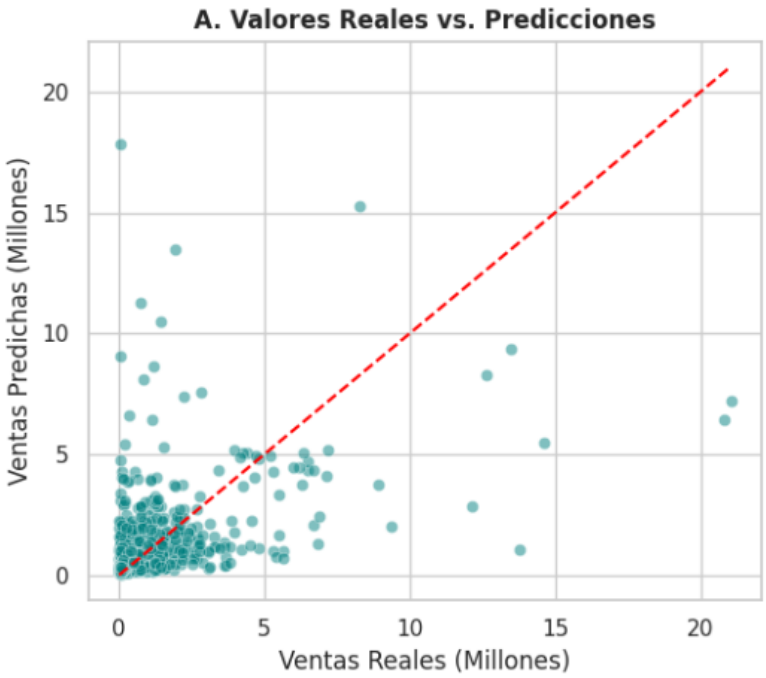

Modelo Regularizado

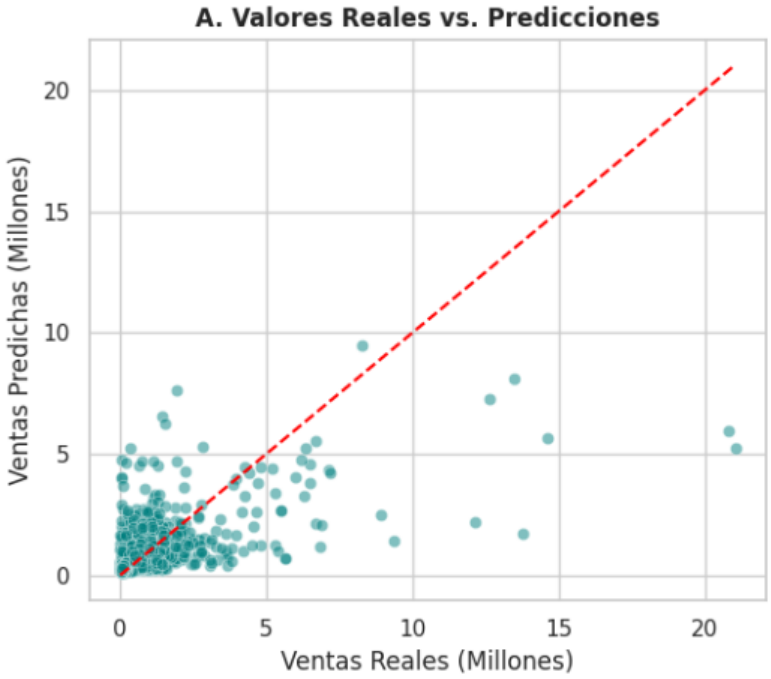

Evaluación Visual: Dispersión de Predicciones

- Comparativa de las predicciones frente a los valores reales.
- El modelo regularizado reduce la dispersión extrema y se ajusta más a la línea ideal, mitigando el *Overfitting* del modelo base.

Modelo Base

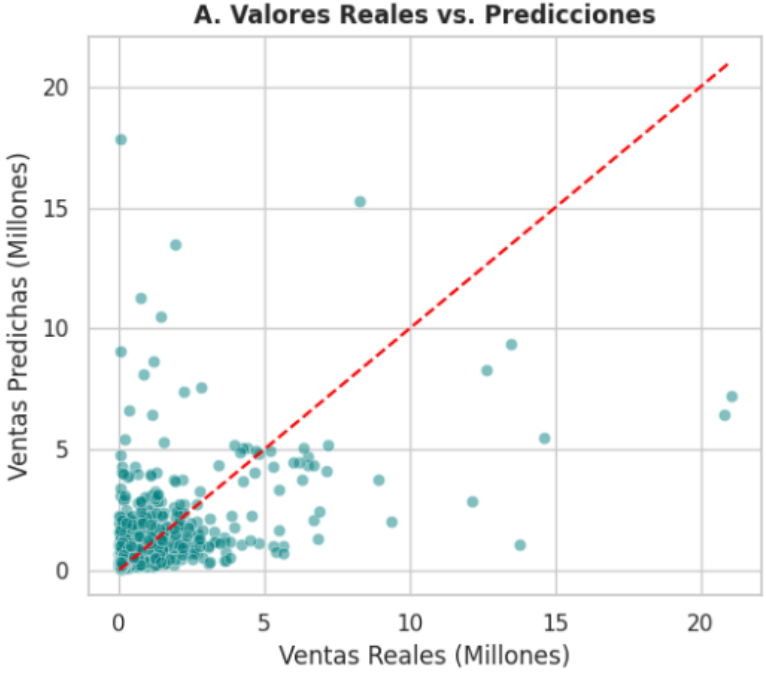

Modelo Regularizado

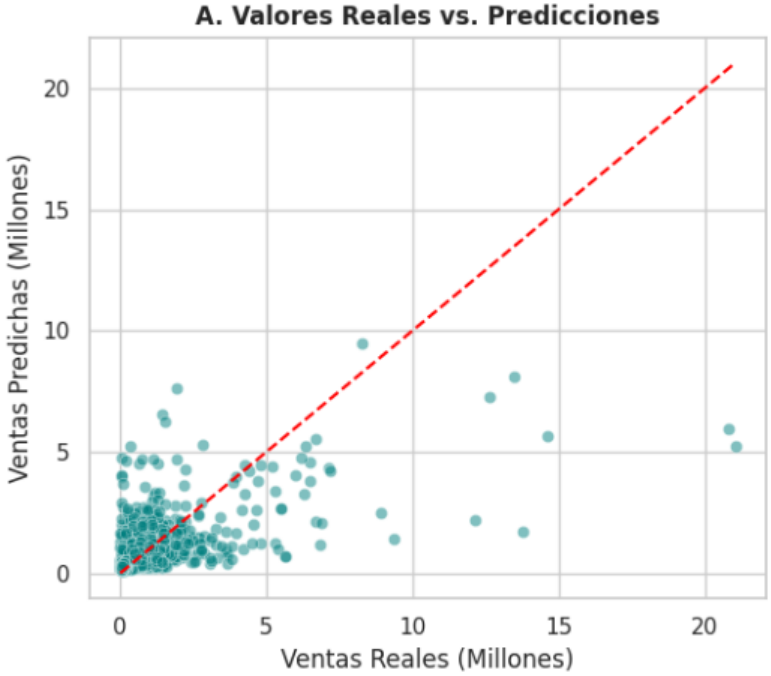

Evaluación Visual: Distribución de Residuos (Errores)

- **Gráfico de Residuos:** Logramos formar una campana bien centrada en cero.
- Esto prueba que nuestro algoritmo **no tiene un sesgo direccional** (no subestima ni sobreestima sistemáticamente).

Modelo Base

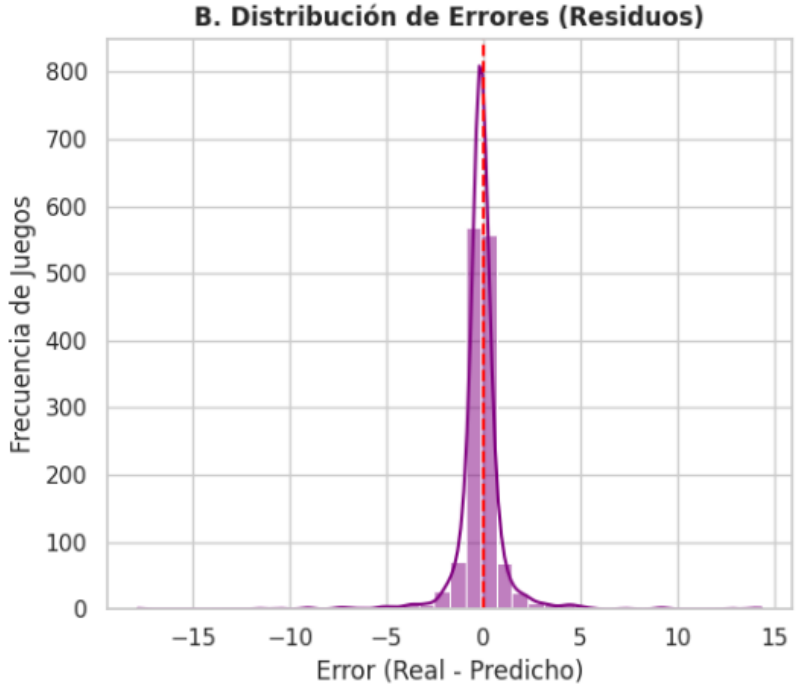

Modelo Regularizado

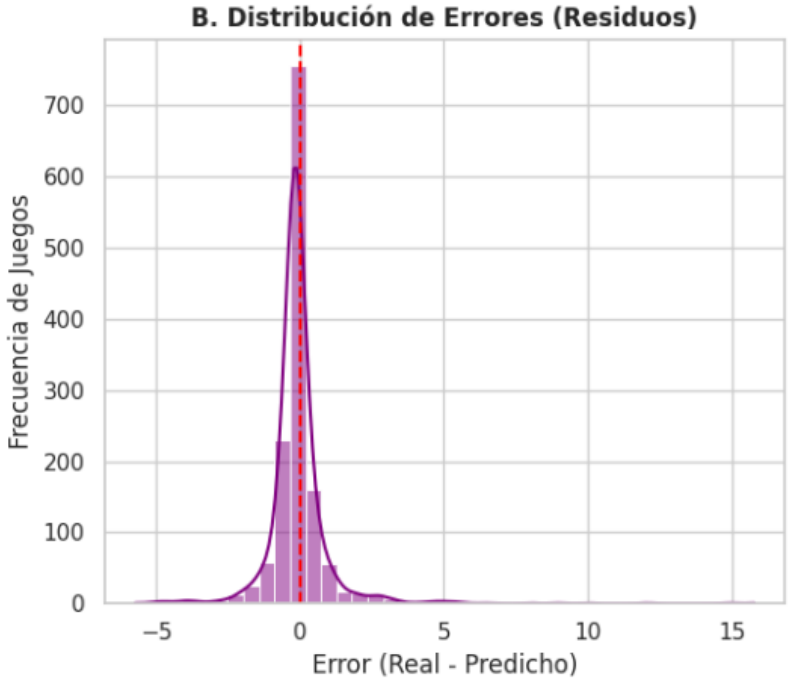

Evaluación Visual: Distribución de Residuos (Errores)

- **Gráfico de Residuos:** Logramos formar una campana bien centrada en cero.
- Esto prueba que nuestro algoritmo **no tiene un sesgo direccional** (no subestima ni sobreestima sistemáticamente).

Modelo Base

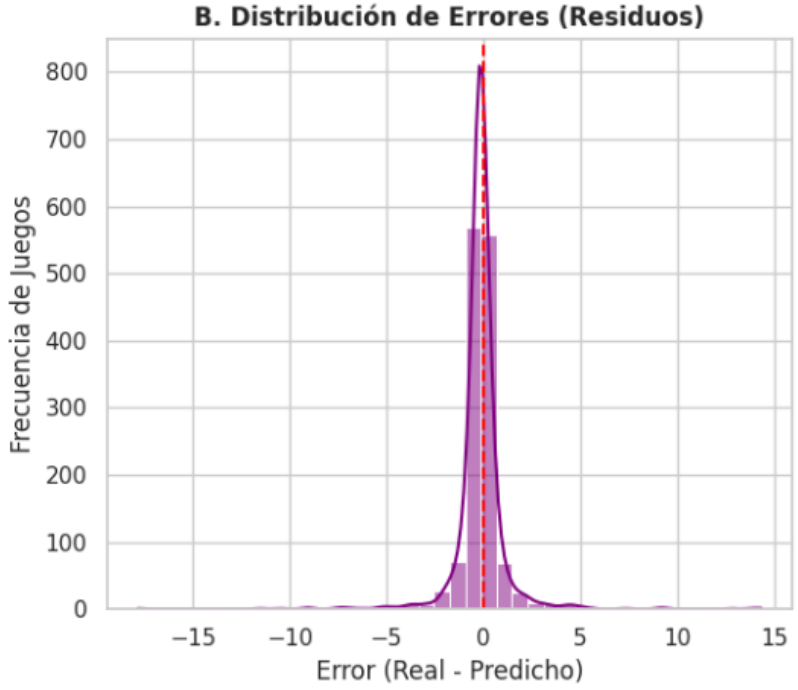

Modelo Regularizado

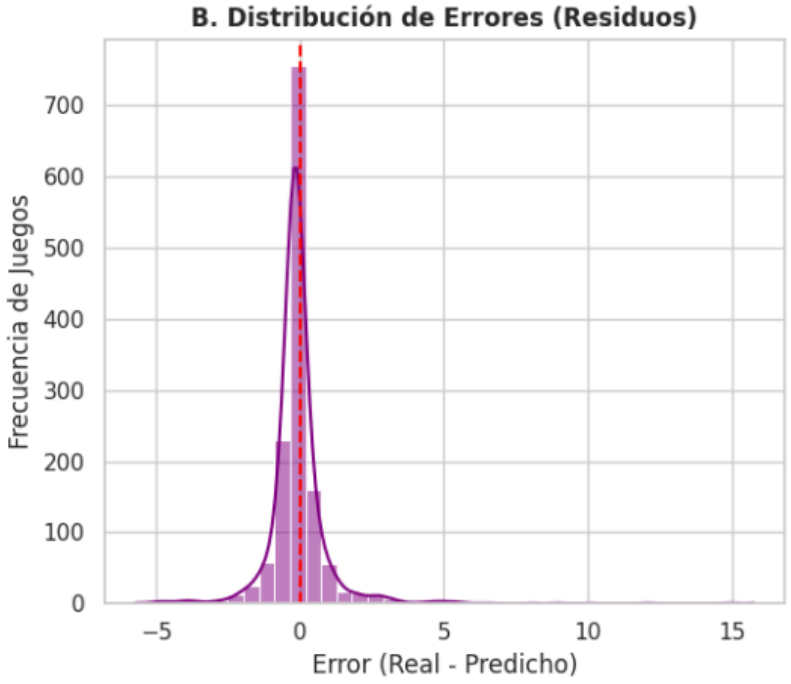

Evaluación Visual: Distribución de Residuos (Errores)

- **Gráfico de Residuos:** Logramos formar una campana bien centrada en cero.
- Esto prueba que nuestro algoritmo **no tiene un sesgo direccional** (no subestima ni sobreestima sistemáticamente).

Modelo Base

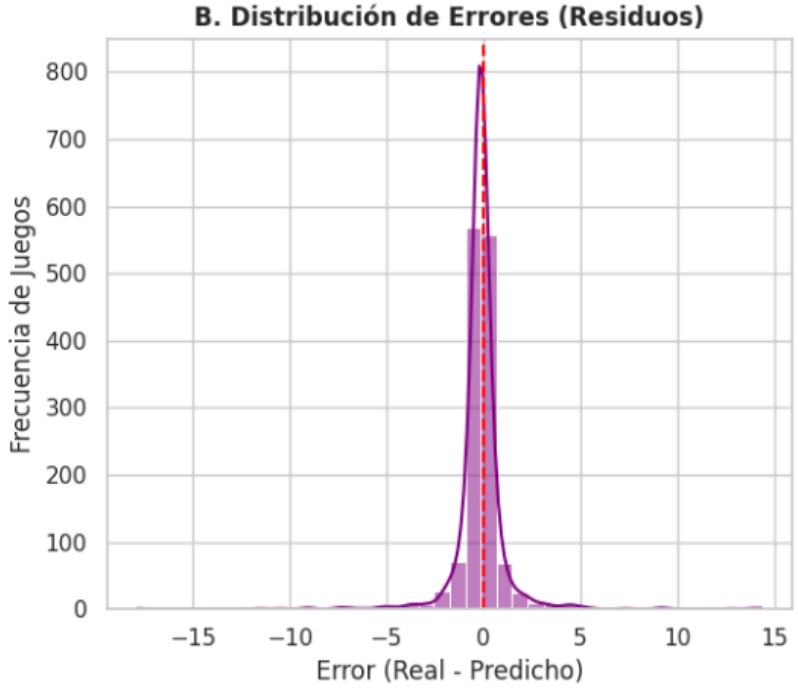

Modelo Regularizado

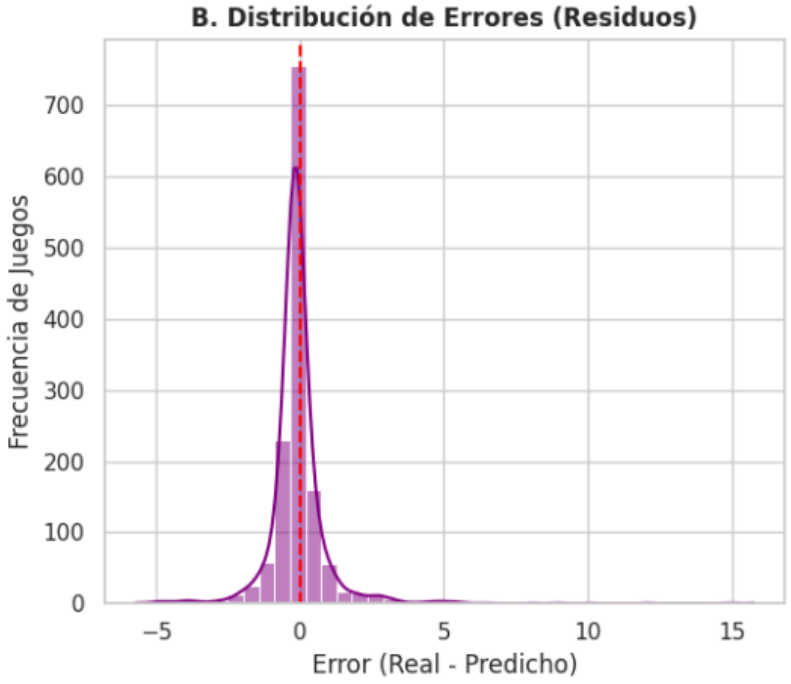

Evaluación Visual: Distribución de Residuos (Errores)

- **Gráfico de Residuos:** Logramos formar una campana bien centrada en cero.
- Esto prueba que nuestro algoritmo **no tiene un sesgo direccional** (no subestima ni sobreestima sistemáticamente).

Modelo Base

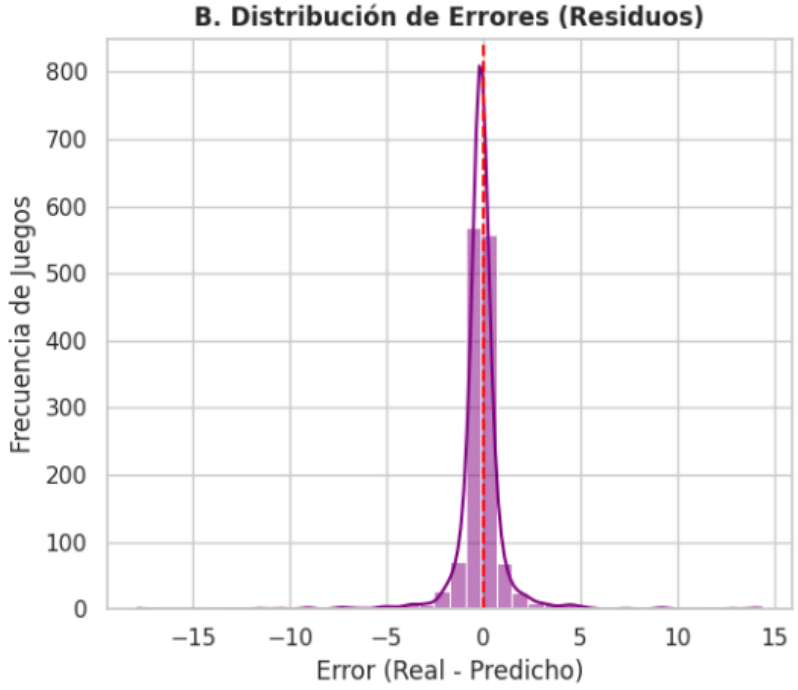

Modelo Regularizado

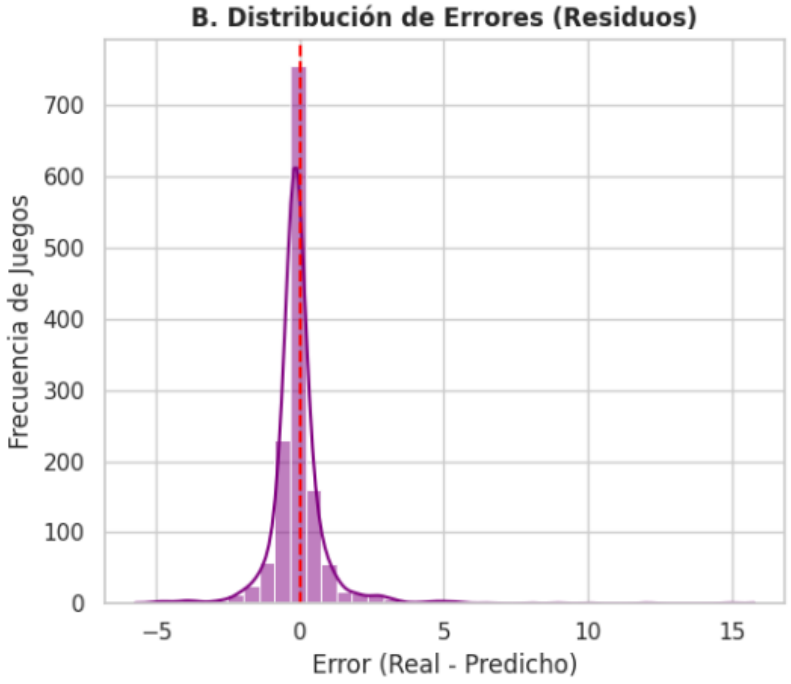

Evaluación Visual: Importancia de Variables

- La interacción de la comunidad (`User_Count`) y la presión de la crítica especializada son las maestras que mueven las ventas.
- Curiosamente, el **género del juego resulta irrelevante matemáticamente** a la hora de alcanzar el éxito de copias.

Modelo Base

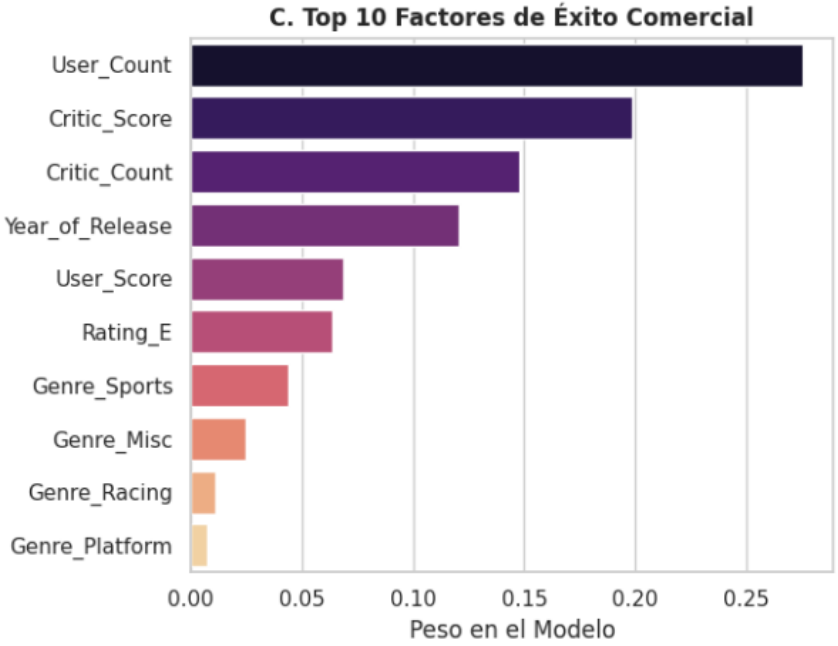

Modelo Regularizado

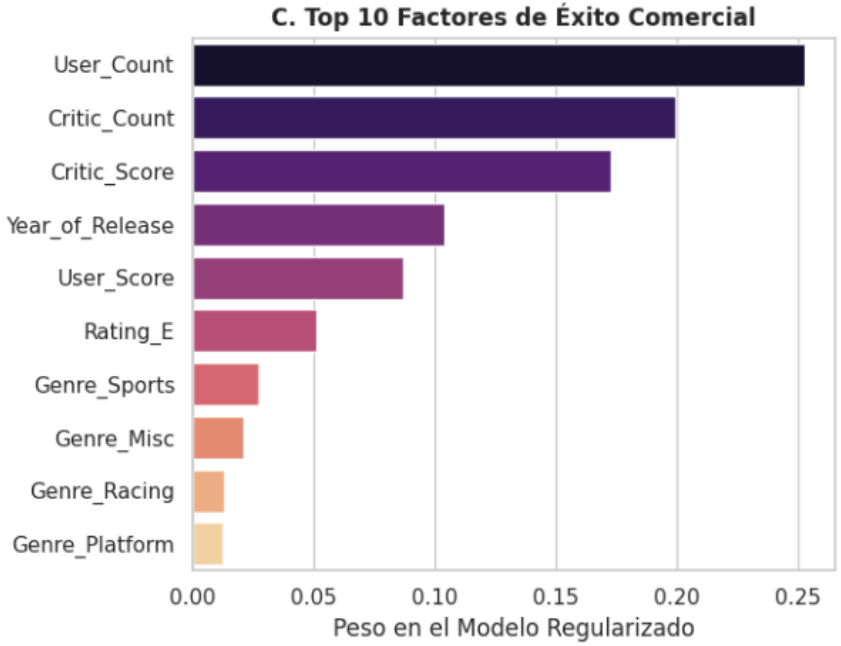

Evaluación Visual: Importancia de Variables

- La interacción de la comunidad (`User_Count`) y la presión de la crítica especializada son las maestras que mueven las ventas.
- Curiosamente, el **género del juego resulta irrelevante matemáticamente** a la hora de alcanzar el éxito de copias.

Modelo Base

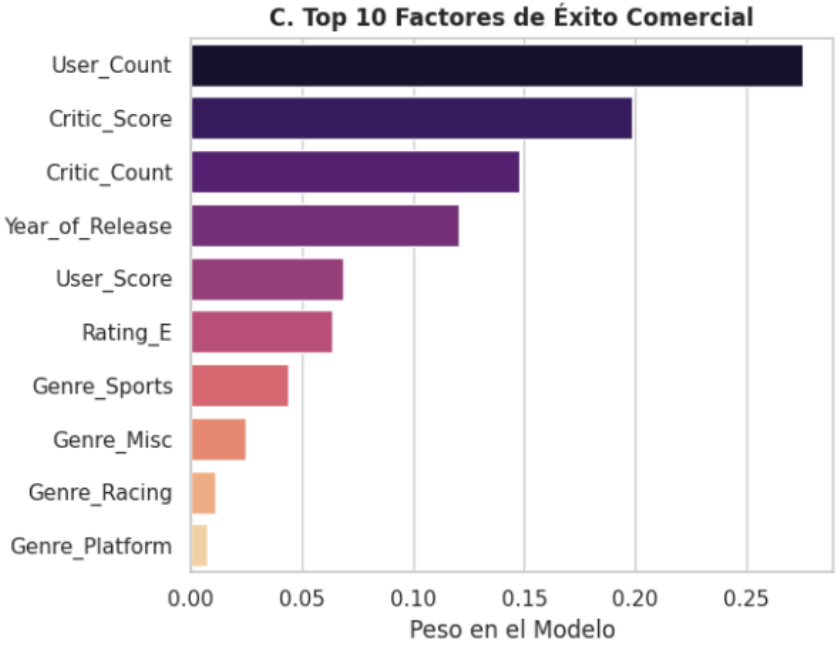

Modelo Regularizado

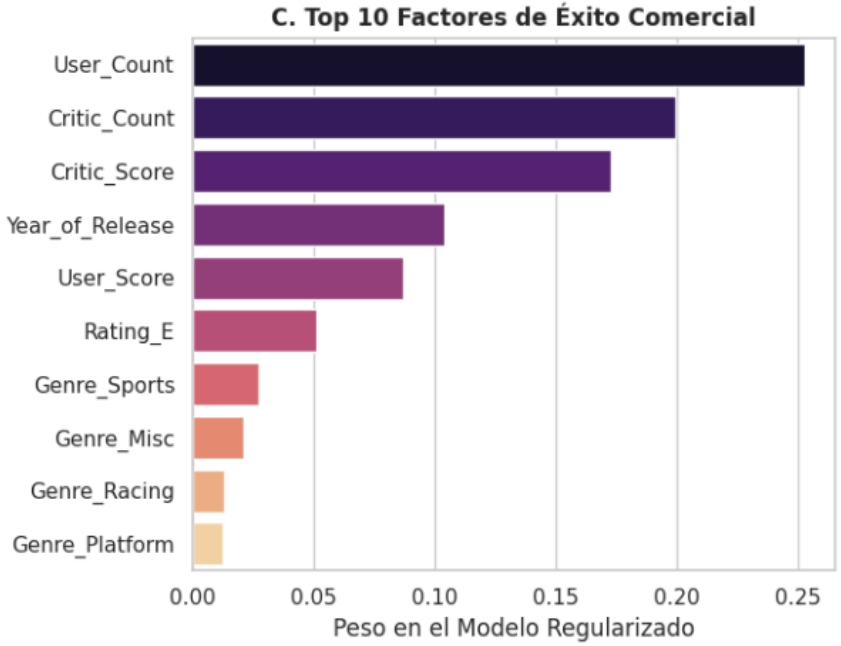

Evaluación Visual: Importancia de Variables

- La interacción de la comunidad (`User_Count`) y la presión de la crítica especializada son las maestras que mueven las ventas.
- Curiosamente, el **género del juego resulta irrelevante matemáticamente** a la hora de alcanzar el éxito de copias.

Modelo Base

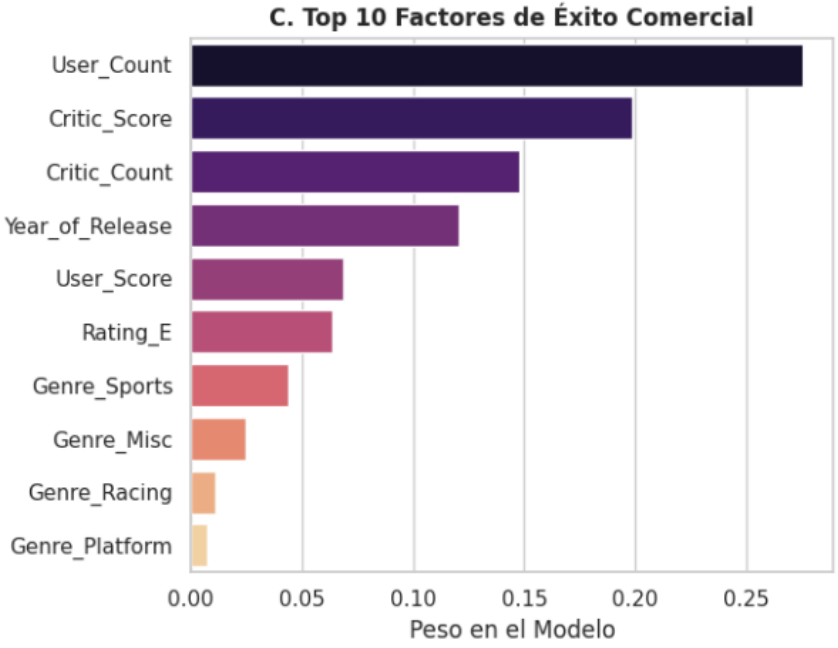

Modelo Regularizado

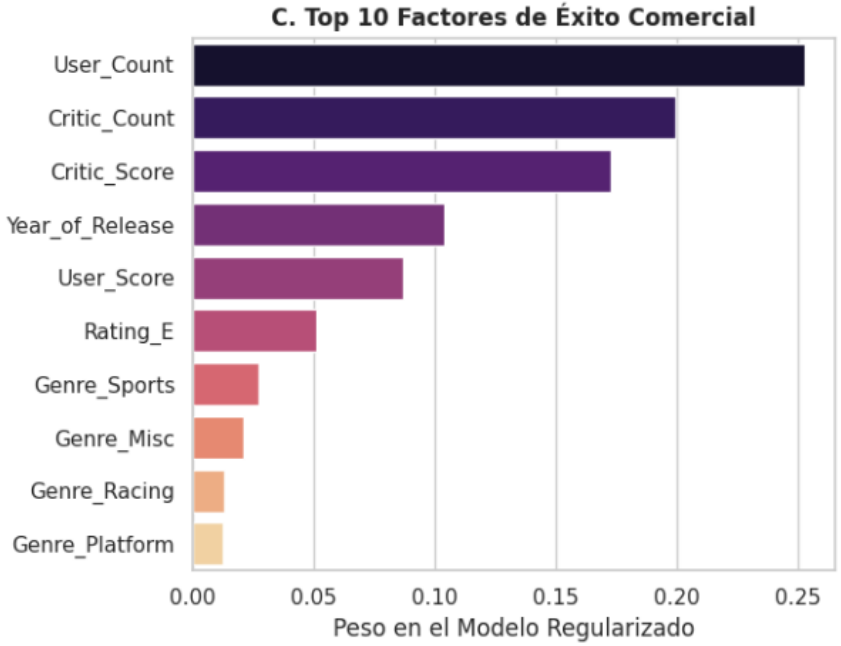

Evaluación Visual: Importancia de Variables

- La interacción de la comunidad (`User_Count`) y la presión de la crítica especializada son las maestras que mueven las ventas.
- Curiosamente, el **género del juego resulta irrelevante matemáticamente** a la hora de alcanzar el éxito de copias.

Modelo Base

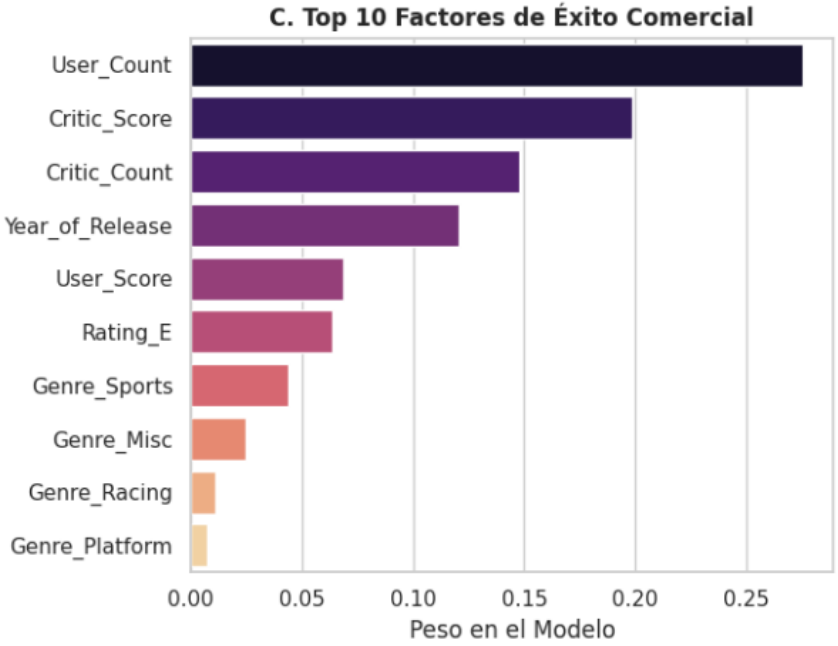

Modelo Regularizado

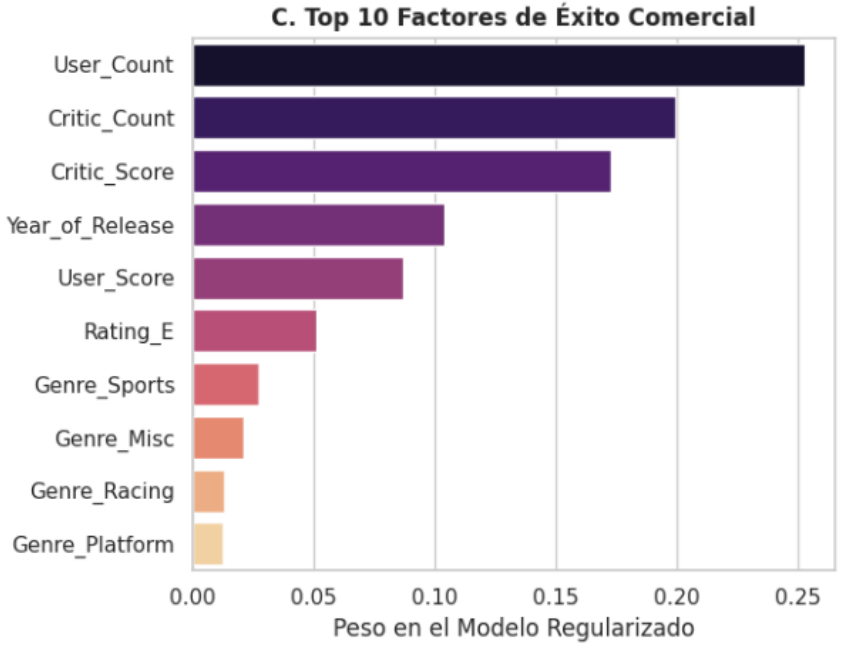

Cierre: Simulador Proyectivo

No dejamos el modelo en teoría. Exportamos el artefacto entrenado (`.pkl`) e implementamos un simulador interactivo para consultar nuevas propuestas de inversores.

Conclusión de Negocio para Inversores

Dejen de perseguir el "género de moda" (Shooters, Deportes, etc.). El modelo matemático es implacable: **Inviertan en pulir la calidad de su software (buenas críticas) y en construir campañas comunitarias masivas**. La data nos demuestra que sólo así se garantiza la rentabilidad masiva.

Cierre: Simulador Proyectivo

No dejamos el modelo en teoría. Exportamos el artefacto entrenado (`.pkl`) e implementamos un simulador interactivo para consultar nuevas propuestas de inversores.

Conclusión de Negocio para Inversores

Dejen de perseguir el "género de moda"(Shooters, Deportes, etc.).
El modelo matemático es implacable: **Inviertan en pulir la calidad de su software (buenas críticas) y en construir campañas comunitarias masivas**. La data nos demuestra que sólo así se garantiza la rentabilidad masiva.

Referencias

¡Gracias!

dm-25.ucv.ai