Predicción de victorias en partidas 1v1 de Super Smash Bros Ultimate

Proyecto final de Aprendizaje Automático

Miguel Ciavato C.I. 30541929
Jhonatan Homsany C.I. 30.182.893

Marzo, 2026

Contexto

Contexto

- Super Smash Bros Ultimate (SSBU) es un videojuego de lucha desarrollado por Nintendo, es el crossover más grande de la industria.
- Actualmente, el juego cuenta con 87 personajes jugables contando los DLC's.
- El videojuego se adapta a todo tipo de jugadores.
- Aunque cuenta con 103 escenarios para los combatos, los torneos competitivos suelen reducir este conjunto.

Contexto

- Todos los jugadores comienzan en "la llave de los ganadores".
- En esta llave, se hacen enfrentamientos con sets se 3,5 o 7 partidas.
- Si un jugador pierde, pasa a la llave de perdedores. Si vuelve a perder, estando en esta llave, es descalificado.
- En la final, el mejor jugador de la llave de ganadores, juega contra el mejor de la llave de perdedores.

Contexto

Figura 1: Escenarios usados comunmente en competencias

Contexto

- En la primera partida, están disponibles únicamente los escenarios starters.
- Acá, un jugador elimina de la lista un escenario y luego el otro elimina dos. En este punto, estarán disponibles tres escenarios que pueden ser seleccionados por el jugador que realizó el primer bloqueo.
- Tras la primera partida, están disponibles los escenarios en "counterpick" y se repite el procedimiento de eliminación y selección de la primera partida.

Muestreo

Muestreo

Recolección de Datos

Para obtener los datos, se usó la web de **start.gg** (una plataforma de esports), que tiene una API accesible desde GraphQL para consultar datos sobre los eventos que se realizan ahí.

- Se filtraron los torneos que tuvieran 100 participantes o más, para evitar torneos de bots o de prueba.
- Se usaron datos exclusivamente a partir de **2022**, ya que en ese año hubo un parche, por lo que la data previa no es válida.
- Se tomaron eventos de 2000 torneos aleatoriamente, para evitar sesgos de jugadores específicos o regiones.
- Como resultado, se obtuvieron 100.000 registros de partidas individuales (1 vs 1).

Muestreo

Cada una de las entradas del dataset, tiene estas características:

- El orden del juego (numero de la partida).
- El nombre del escenario en el que se jugó la partida.
- El nombre de cada jugador.
- El nombre del personaje que usó cada jugador.
- Un campo para indicar si el jugador 1 ganó.

Exploración

Exploración (Power Index)

- Antes de pasar al preprocesamiento de los datos, se visualizaron estadísticas del dataset para entender mejor el contexto de los datos.
- Lo primero que se hizo fue ver qué personajes eran los "mejores", esta métrica es difícil puesto que una proporción de $\frac{victorias}{partidas}$ usada como métrica, penaliza a aquellos personajes que se usan más y eleva mucho a personajes muy poco usados con los que especialistas siempre terminan ganando.

Exploración (Power Index)

- Obtener estas métricas más fiable es muy valioso para el modelo, por lo que, lo primero que se hizo fue añadir una métrica de tasa de victorias por jugador:

$$\text{win_rate} = \frac{\text{victorias reales} + (m \times C)}{\text{partidas jugadas} + m}$$

- Con m siendo el número mínimo de victorias, y C el promedio de victorias de todos los jugadores.

Exploración (Power Index)

- Ahora, para determinar qué personajes son los mejores, se usaron **puntos**, un personaje gana puntos contra otro dependiendo del win_rate de cada jugador.
- Por ejemplo, si un jugador con un win_rate de 0.2 que usa a Mario, le gana a uno con un win_rate de 0.8 que usa a Link, Mario obtendrá 0.8 puntos.
- Este total de puntos, se divide entre el total de partidas de ese personaje, para obtener la métrica del **Power Index**

$$\frac{\text{Suma de puntos}}{\text{Total de partidas}} \times \log_{10}(\text{Partidas} + 1)$$

- Esta es una de las métricas que utilizan en rankings como LumiRank y en comunidades de Reddit del juego, y está inspirada en métricas como el ELO en ajedrez.

Exploración (Gráficas)

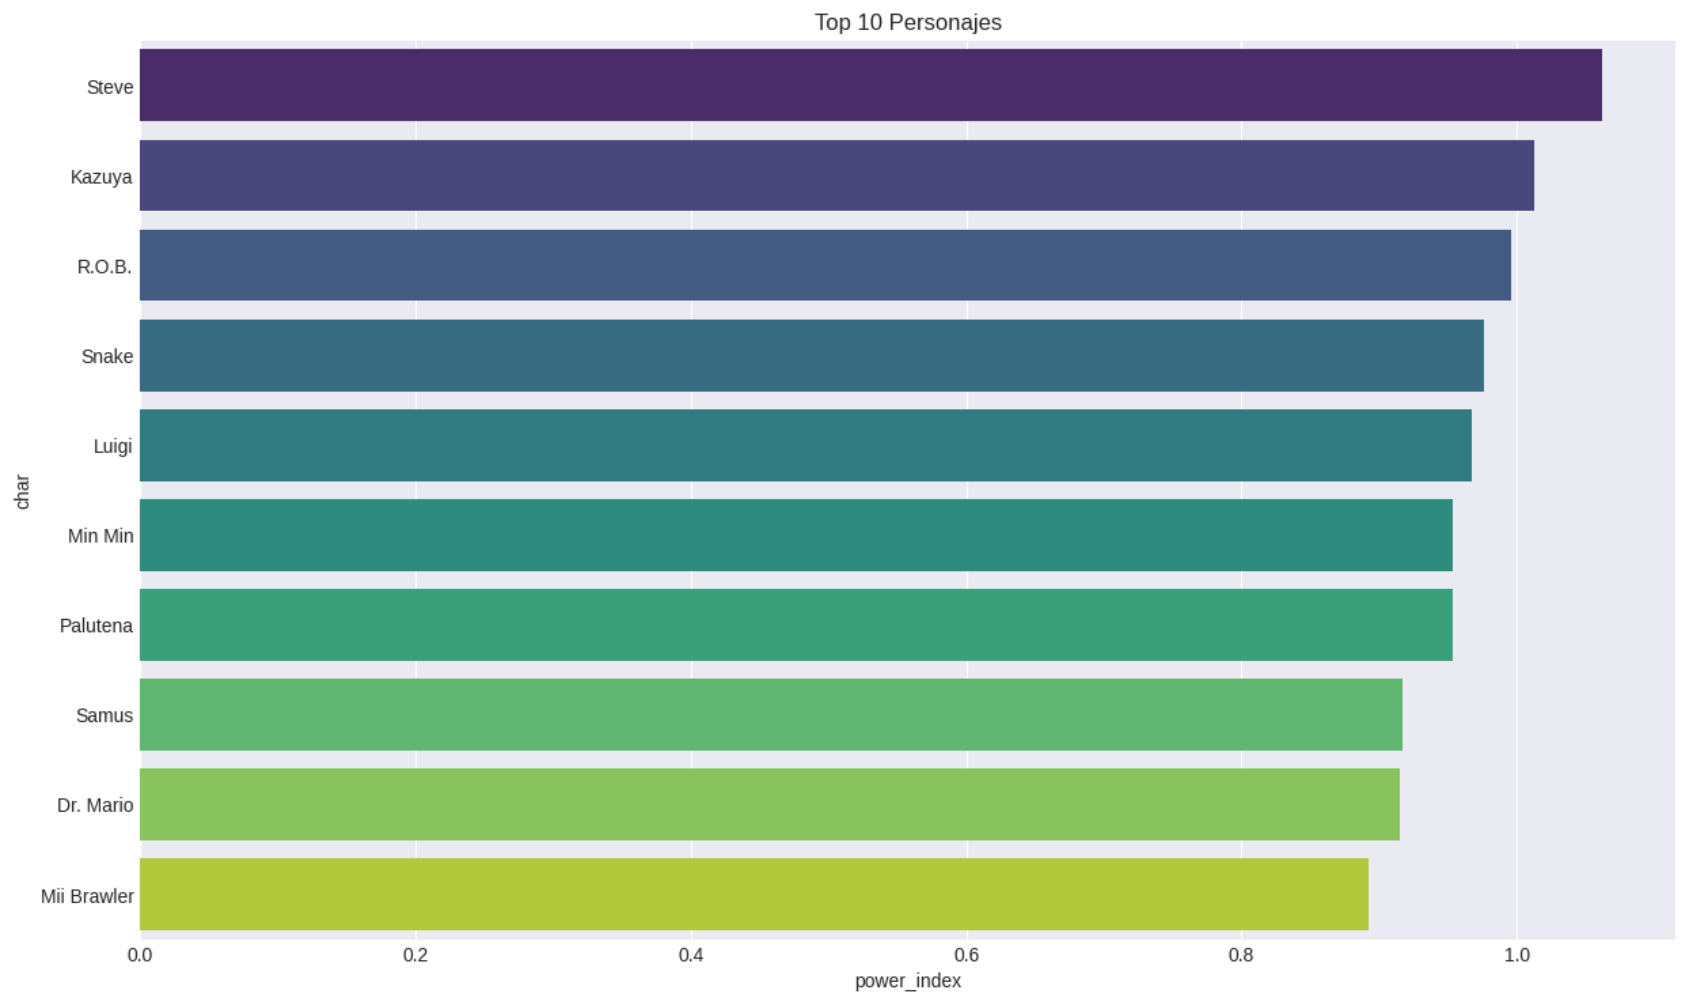

Figura 2: Top personajes según el power index

Exploración (Gráficas)

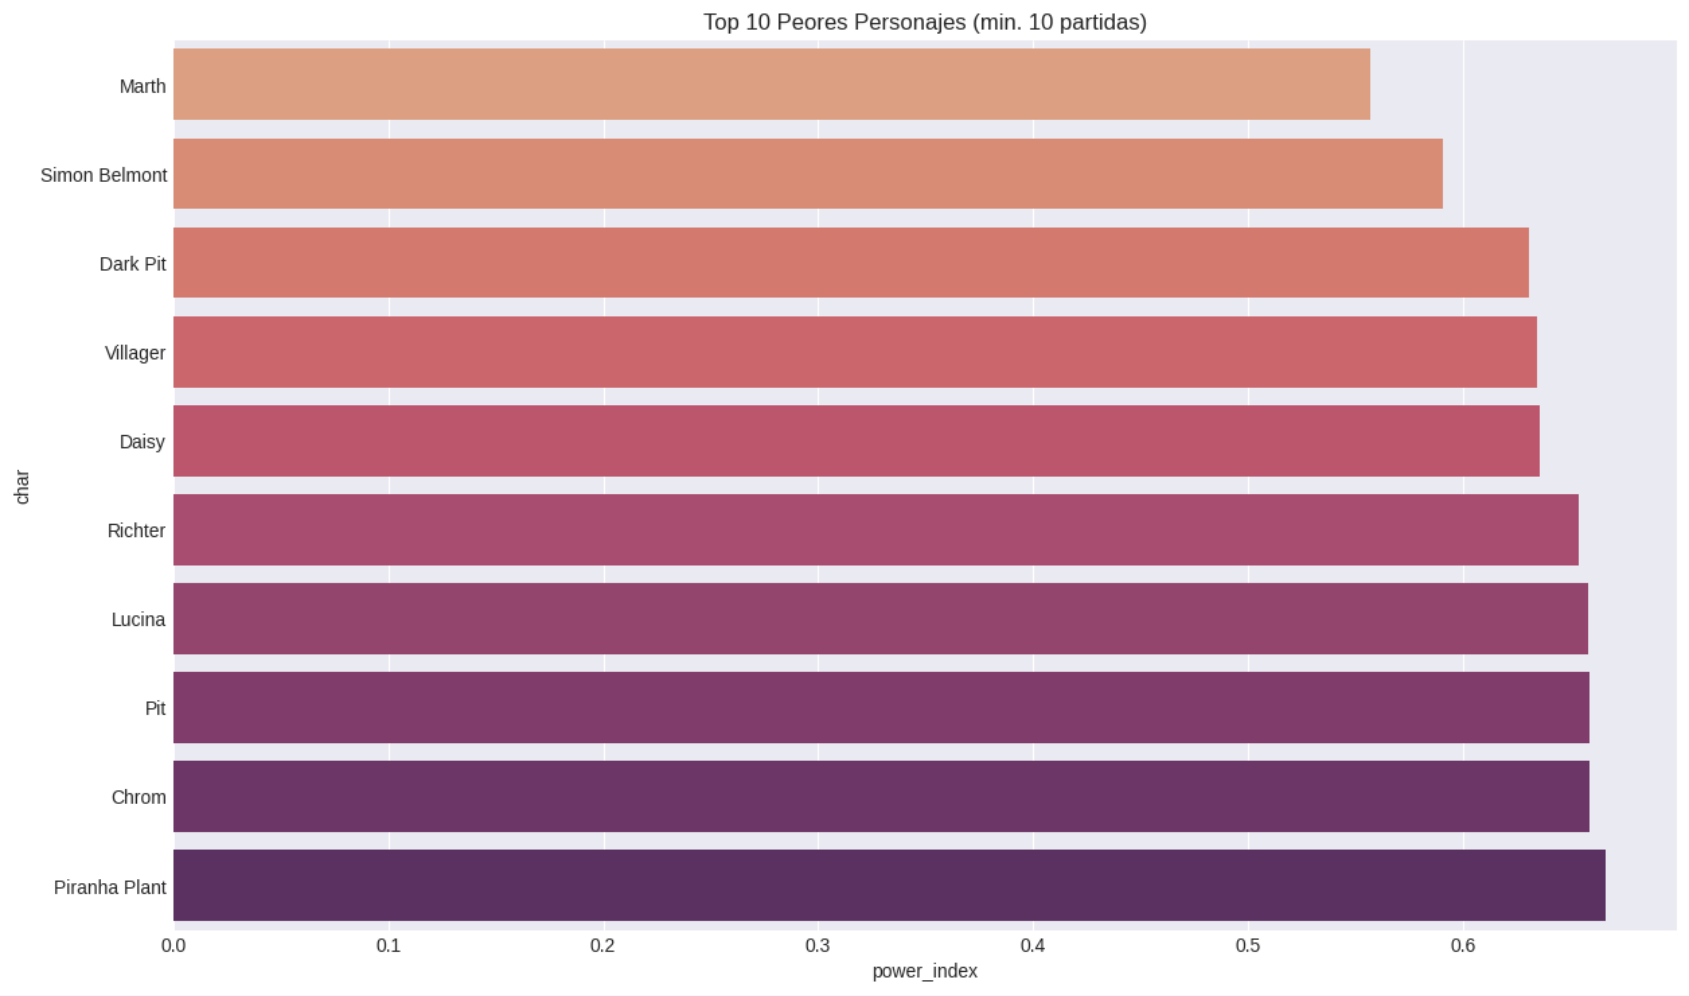

Figura 3: Peores personajes según el power index

Exploración (Gráficas)

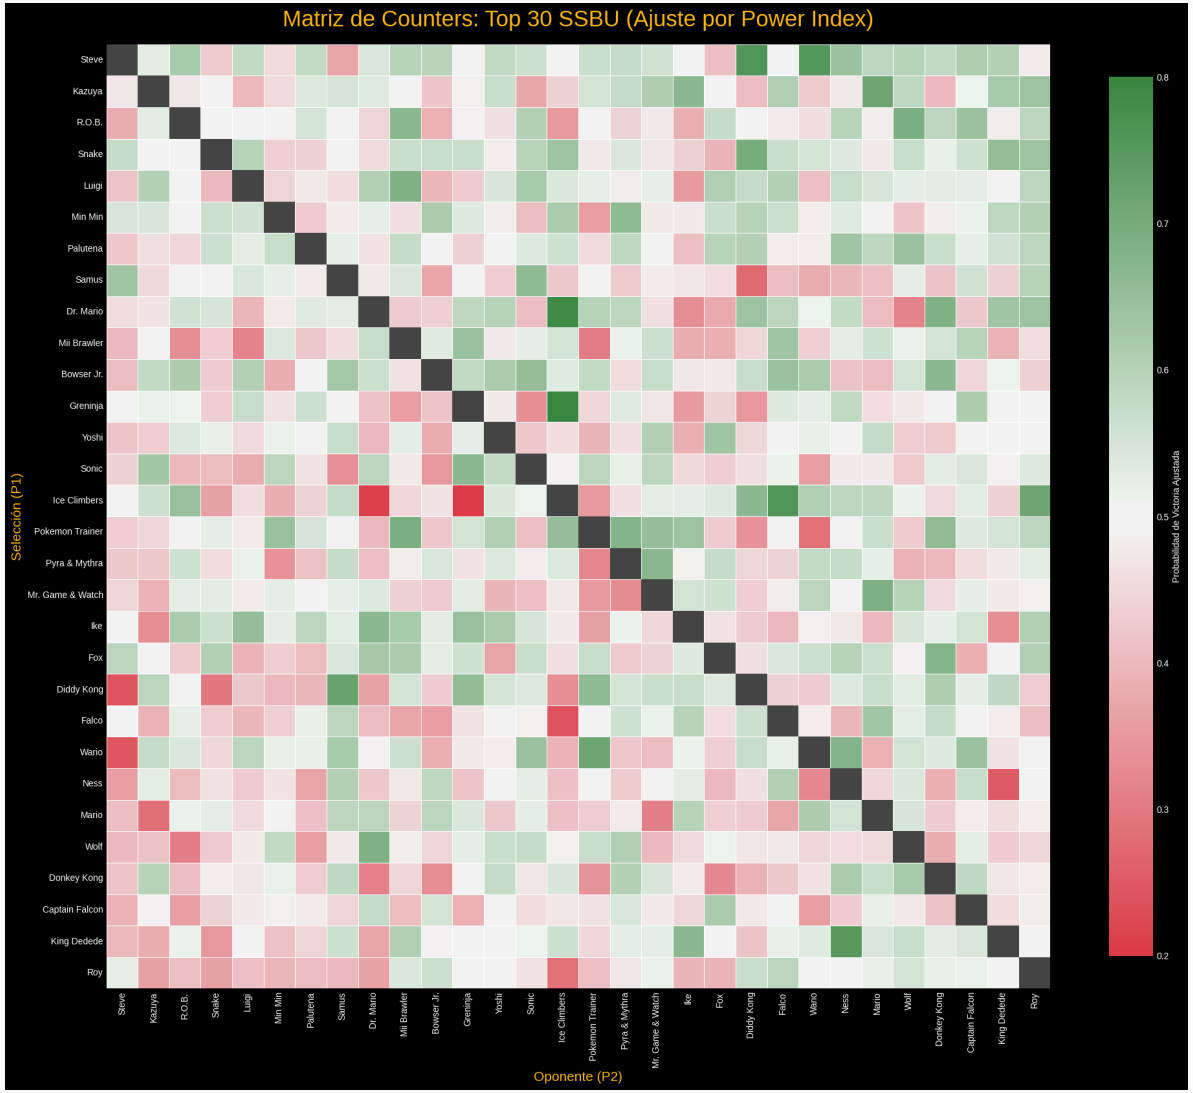

Figura 4: Matriz de Match Up entre personajes

Exploración (Gráficas)

Figura 5: Top oficial

Exploración (Conclusiones)

Todo esto se hizo como una antesala al modelo, para corroborar que:

- Existen personajes que son mejores contra otros, independientemente de la habilidad del jugador (hay un desbalance claro).
- El uso del win_rate y power index tiene un potencial predictivo, ya que las estadísticas que se consiguieron son similares a las publicadas en rankings como LumiRank.
- Esto nos lleva a la hipótesis de que usar estás métricas, en conjunto con el escenario y número de partida pueden permitirle a un modelo hacer buenas predicciones.

Modificación (Preprocesamiento)

Modificación

- Para preprocesar los datos, inicialmente se hizo un label encoding para no usar texto en el entrenamiento.
- Se incluyó el **Power Index** de los personajes que usó cada jugador y el **Win-Rate** de cada jugador.
- Se descartaron las partidas con escenarios desconocidos.
- Se usó el StandardScaler para estandarizar las características, removiendo la media y escalando hasta llegar a varianza 1.
- Se uso el 70 % de datos para el entrenamiento y el 30 % para prueba.

Modelado

Modelado (Algoritmo escogido)

- Dadas las características de este dataset, se optó por usar un modelo de regresión logística, ideal para predecir la clase (victoria p1, derrota p1) de una partida en particular.
- Es importante resaltar que las predicciones del modelo se basan exclusivamente en las condiciones iniciales de la partida, por lo que no se toman en cuenta otras condiciones que puedan afectar la victoria mientras la partida está en curso.

Modelado (Regularización)

- Lo primero que se hizo fue definir un espacio logaritmico np.logspace(-4, 2, 25), para encontrar el mejor hiperparámetro de regularización C para el modelo de regresión logística en ese espacio.
- Se hizo uso de validación cruzada con 5 folds, balanceando las clases y usando la penalización L1.

Modelado (Regularización)

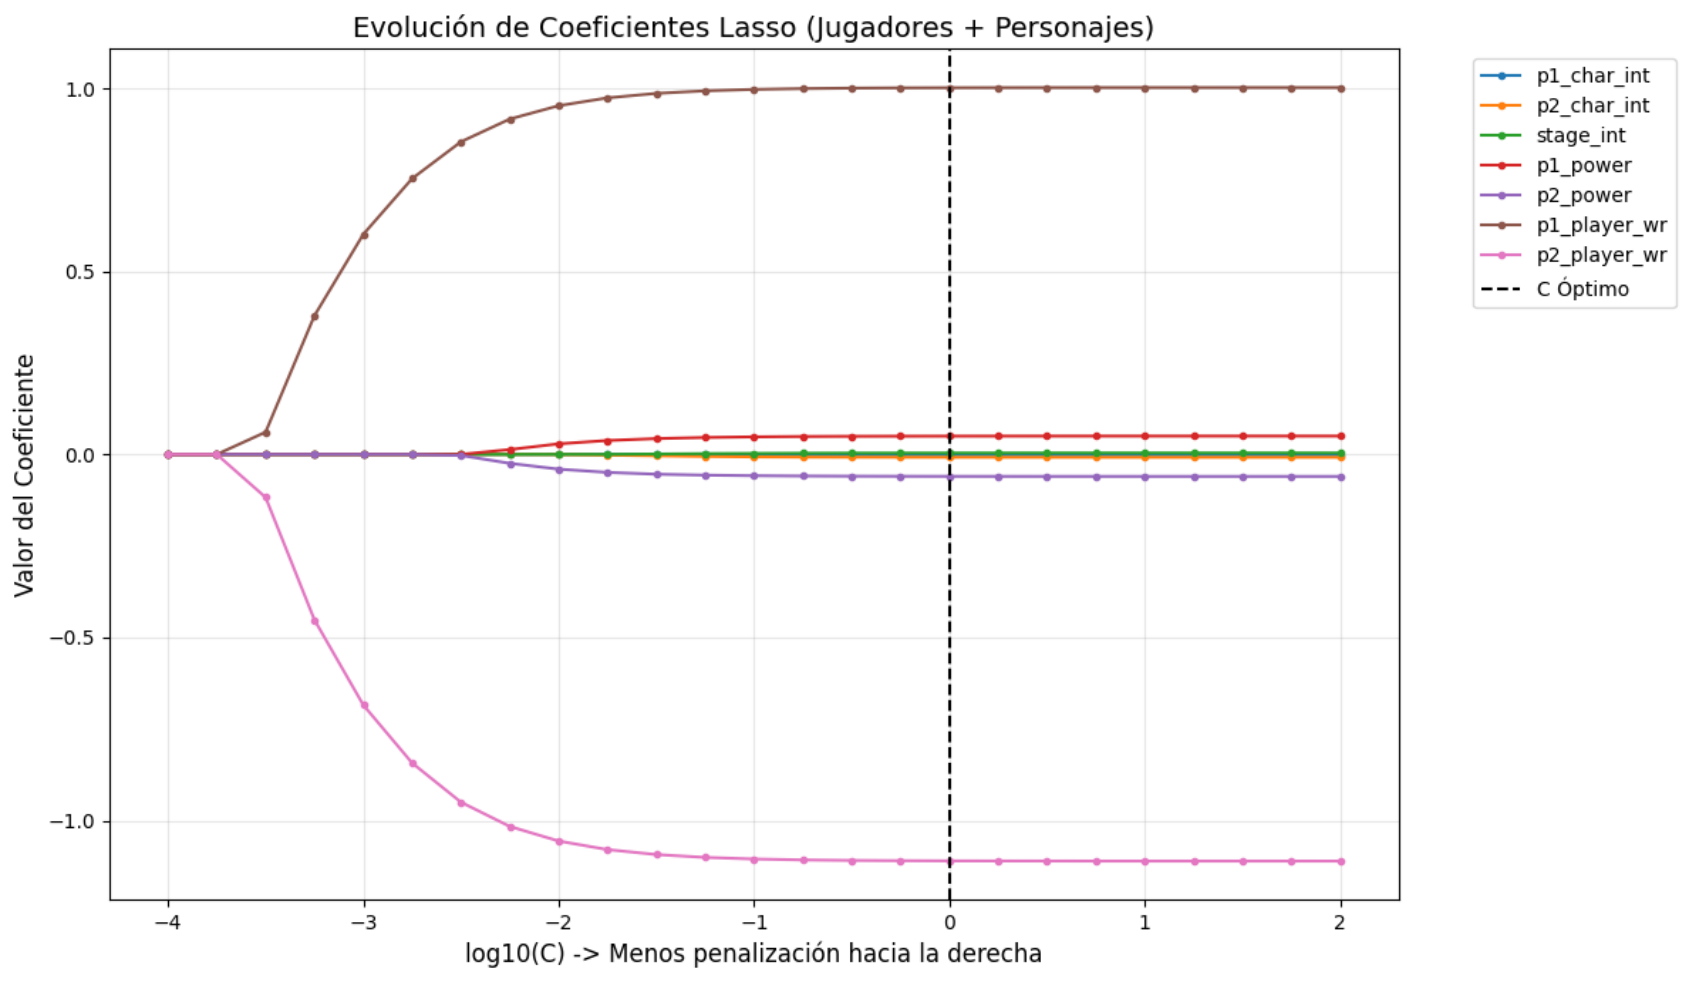

Figura 6: Evolución de coeficientes en el camino de regularización

Modelado (Regularización)

- El impacto de las variables tras aplicar Lasso nos indica que la mejor manera que tenemos para predecir al ganador de una partida es en base a su **consistencia** (su Win-rate), seguida de la viabilidad técnica del personaje. Seguido de esto, tenemos el impacto del escenario que si bien afecta al personaje, los jugadores más habilidosos son capaces de adaptarse a este tipo de situaciones para lograr la victoria.

Modelado (Árboles de decisión)

- Aparte de regresión Logística, probamos otros modelos, para comparar el rendimiento
- Con árboles de decisión, se usó un límite de 3 niveles, con pesos de clases balanceados, utilizando el win_rate de los jugadores como criterio para dividir los datos en cada nodo del árbol, sabiendo que estas son las variables más relevantes para la victoria.

Modelado (Árboles de decisión)

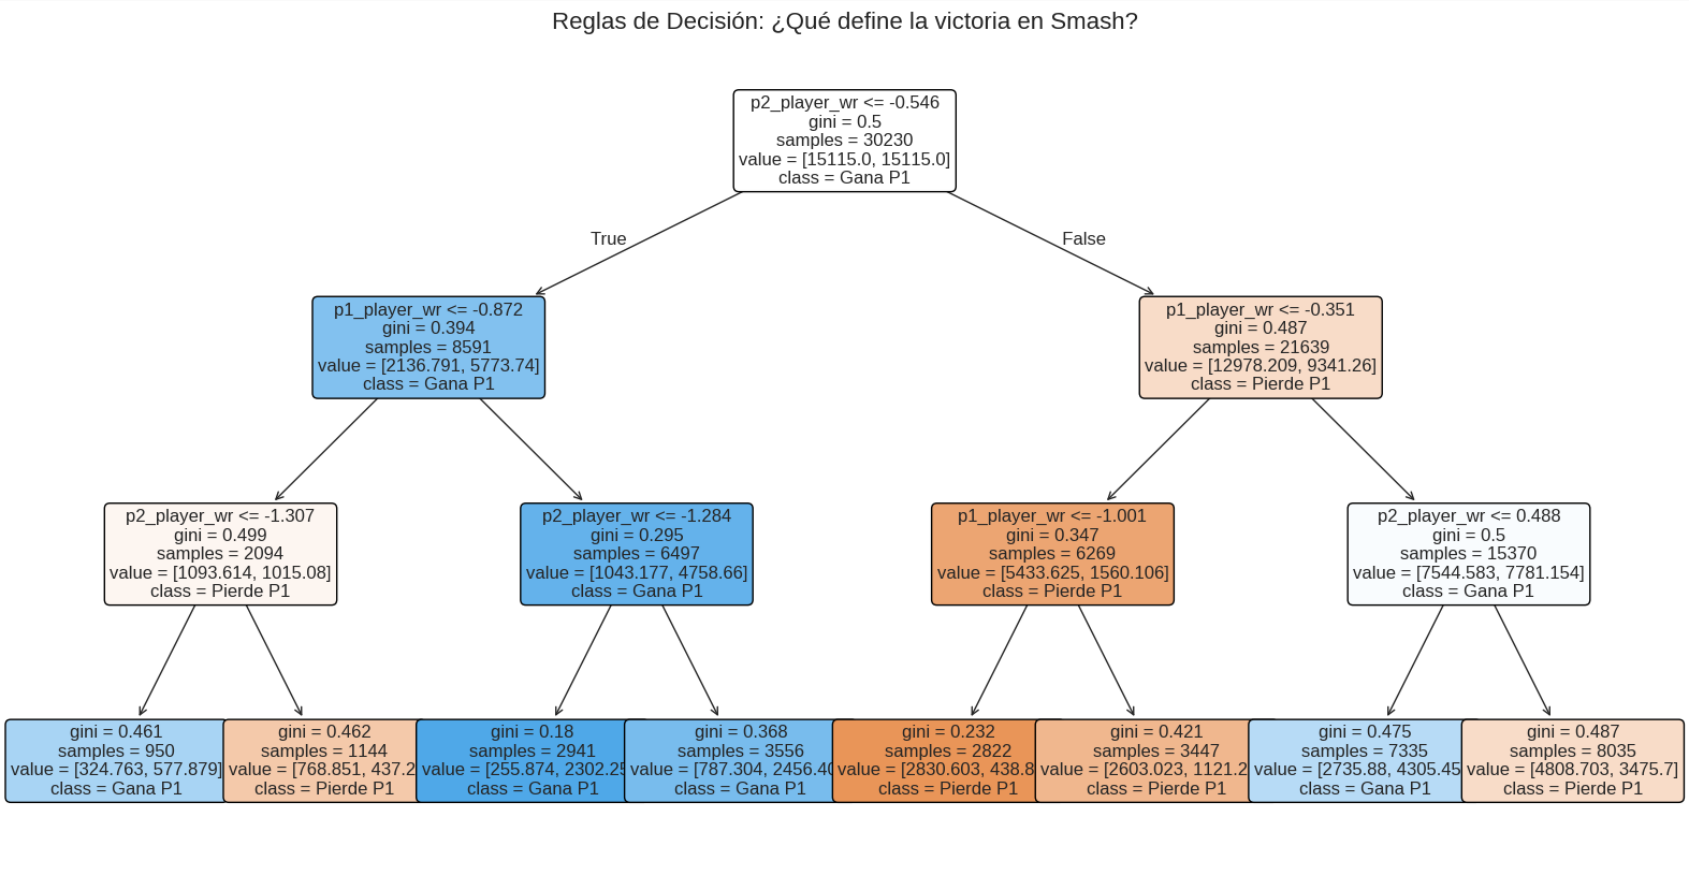

Figura 7: Árbol de decisión resultante

Evaluación

Evaluación

También se usaron Máquinas de soporte vectorial, con un peso de clases balanceado, obteniendo estos resultados:

Modelo	Tipo	F1-Score	Precisión Bal.
Regresión Logística	**Supervisado**	**0.7376**	**70.95 %**
Árbol de Decisión	Supervisado	0.7012	68.47 %
SVM	Supervisado	0.6830	57.22 %

Tabla 1: Métricas finales de desempeño.

Evaluación

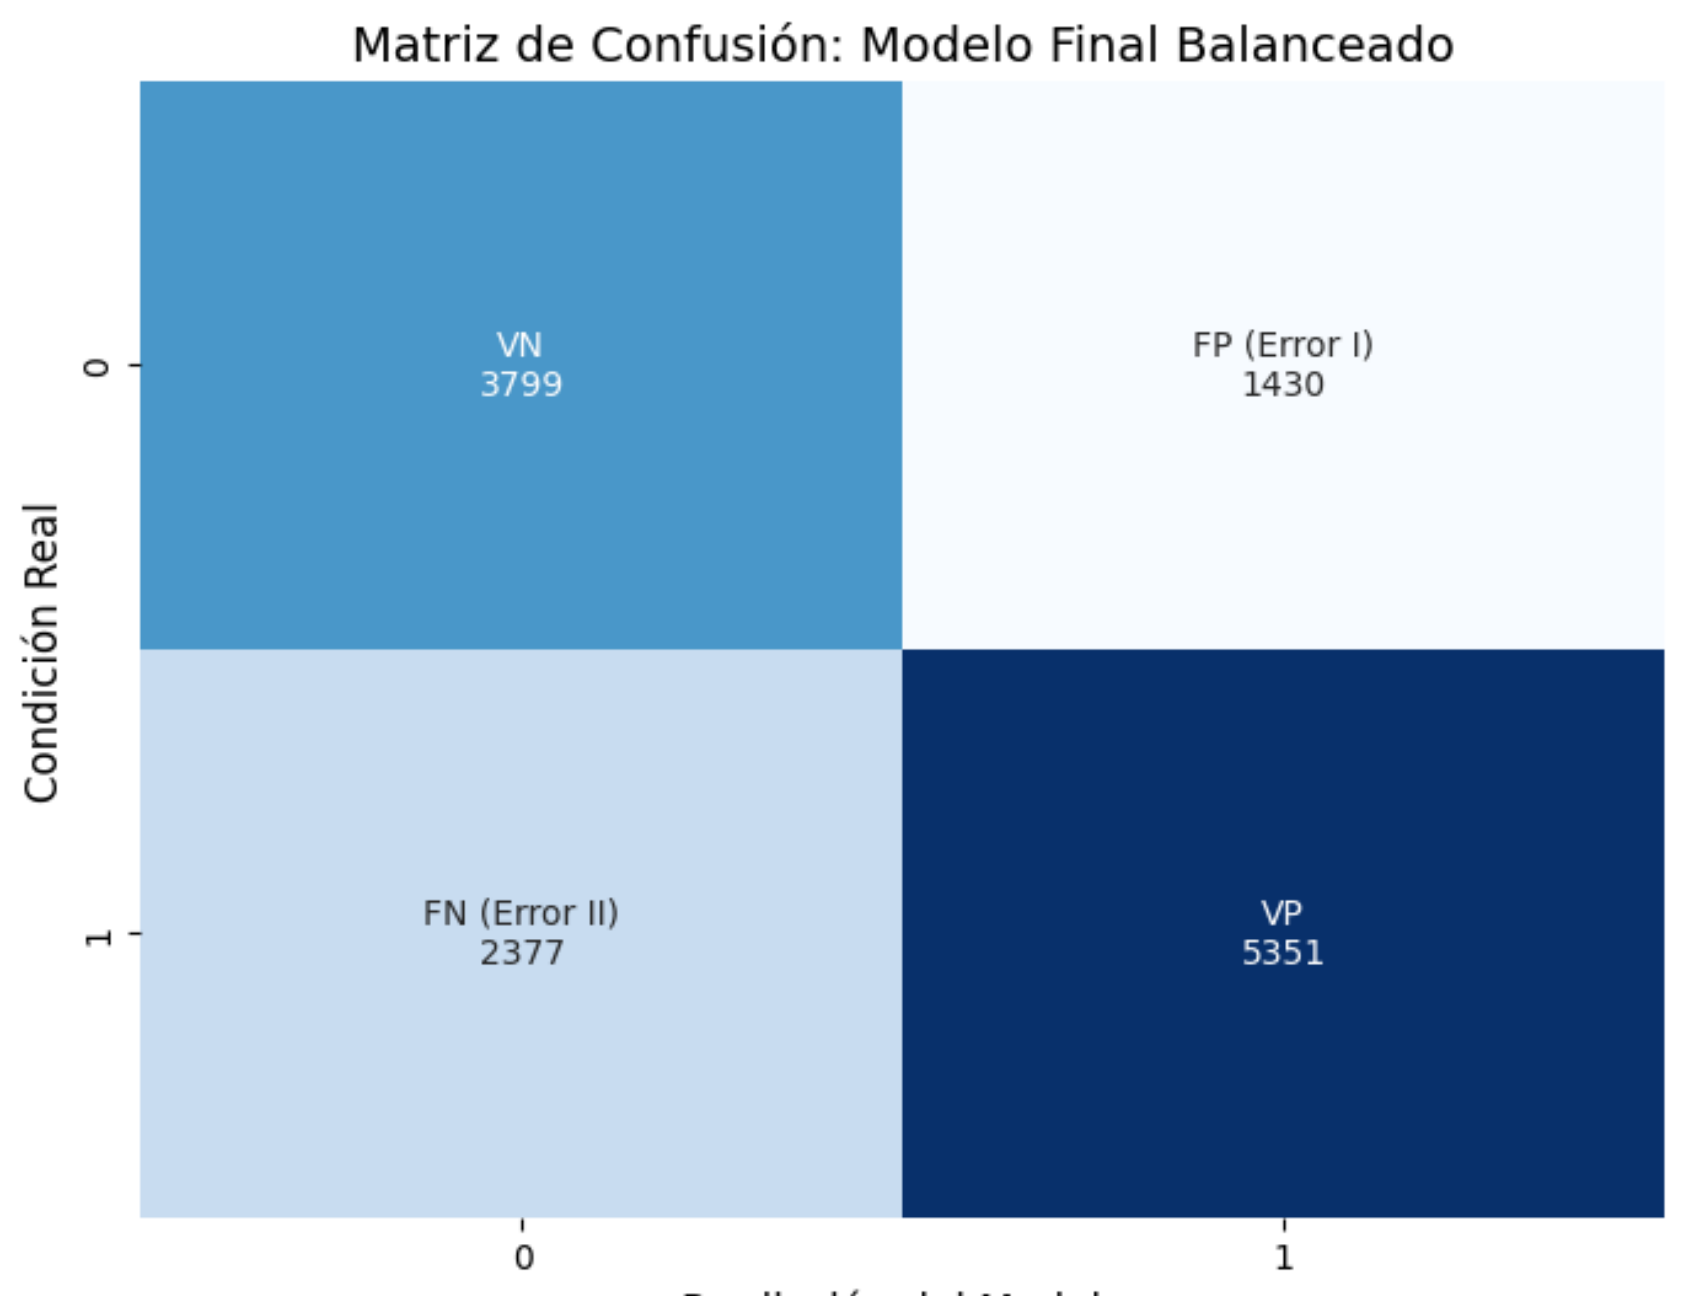
Matriz de Confusión: Modelo Final Balanceado
VN
3799
FP (Error I)
1430
FN (Error II)
2377
VP
5351
Condición Real
0
1
0
1

Conclusiones

- La **Regresión Logística** demostró ser el modelo más robusto (70.95 % de precisión y 0.73 en Score F1), sugiriendo que la ventaja en SSBU puede modelarse de forma lineal mediante los diferentes atributos.
- El 30 % de error restante se atribuye a variables no contenidas en el dataset, como la psicología del jugador, la fatiga y la adaptación en tiempo real.
- Este modelo confirma que es posible predecir el éxito competitivo basándose en la ingeniería del personaje.

Página web de prueba

¡Gracias por su atención!

¿Alguna pregunta?